

LogChirpy

Master in Mobile Computing
Mobile Computing Project"

SoSe 2025

Prof. Dr. Arjan Kuijper

- Final Report -

LogChirpy - Ornithological Archival App Bird Watching Application with AI-Powered Recognition

vorgelegt von:

Martin Lauterbach

Luis Wehrberger

Younna Samounah

Master in Mobile Computing

Contact addresses:

martin.lauterbach@student.hs-rm.de

luis.wehrberger@student.hs-rm.de

younna.samounah@student.hs-rm.de

Submitted on: 19. Juni 2025

Abstract

LogChirpy is a comprehensive mobile bird watching application built with React Native and Expo, featuring advanced AI-powered bird identification through both visual and audio analysis. The app combines local machine learning models for real-time species recognition with a comprehensive archival system, supporting both offline operation and optional cloud synchronization. With multilingual support across 6 languages and a complete database of 30,000+ global bird species, LogChirpy serves both amateur nature enthusiasts and experienced ornithologists, providing an intuitive platform for documenting and sharing bird observations.

Inhaltsverzeichnis

Abbildungsverzeichnis

Tabellenverzeichnis 1

1. Einführung und Motivation 2

1.1. Motivation	2
1.1.1. Moderne Technologie trifft Naturbeobachtung	2
1.1.2. Mehrsprachigkeit & Wissenszugang	2
1.1.3. Cloud-Integration & Datenschutz	2
1.1.4. Medienverarbeitung & Teilen	3
1.2. Problemstellung	3
1.3. Lösungsansatz	3
1.3.1. KI-gestützte Erkennung	3
1.3.2. Umfassende Dokumentation	4
1.3.3. Benutzerfreundlichkeit	4
1.3.4. Technische Innovation	4

2. Ziele des Projekts 5

2.1. Primäre Ziele	5
2.1.1. Benutzerorientierte Ziele	5
2.1.2. Technische Ziele	5
2.1.3. User Experience Ziele	6
2.2. Quantitative Anforderungen	6
2.2.1. Performance-Ziele	6
2.2.2. Skalierbarkeits-Ziele	6
2.2.3. Genauigkeits-Ziele	7
2.3. Qualitative Anforderungen	7
2.3.1. Benutzerfreundlichkeit	7
2.3.2. Technische Qualität	7
2.3.3. Sicherheit und Datenschutz	7
2.4. Erfolgsmetriken	8
2.4.1. Technische Metriken	8
2.4.2. Benutzer-Metriken	8

3. Anforderungsanalyse 9

3.1. Nutzungskontext	9
3.1.1. Feldnutzung	9
3.1.2. Datenmanagement	9
3.1.3. Soziale Interaktion	9

3.2.	Personas	9
3.2.1.	Persona 1: Amateur-Wanderer mit wöchentlichen Touren	9
3.2.2.	Persona 2: Langjähriger Hobby-Ornithologe	10
3.3.	User Stories	11
3.3.1.	User Story 1: Archivzugriff und Export	11
3.3.2.	User Story 2: Schnelles Teilen kürzlich aufgenommener Bilder	12
3.3.3.	User Story 3: Standort einer Spatzensichtung finden	12
3.3.4.	User Story 4: Erstmalige App-Nutzung	13
3.4.	Funktionale Anforderungen	13
3.4.1.	Quantitative Anforderungen	13
3.4.2.	Qualitative Anforderungen	14
3.5.	Nicht-funktionale Anforderungen	14
3.5.1.	Quantitative Anforderungen	14
3.5.2.	Qualitative Anforderungen	15
3.6.	Systemgrenzen und Einschränkungen	15
3.6.1.	Technische Einschränkungen	15
3.6.2.	Regulatorische Einschränkungen	15
4.	Systemarchitektur und Design	16
4.1.	Systemarchitektur Überblick	16
4.1.1.	Tech Stack	16
4.1.2.	Modulare Struktur	17
4.1.3.	Architekturprinzipien	17
4.2.	Feature-basierte Ordnerstruktur	17
4.3.	Machine Learning Architektur	18
4.3.1.	Unified ML Pipeline	18
4.3.2.	Dual-Model Audio System - Detaillierte Technische Im- plementierung	19
4.4.	Datenarchitektur	23
4.4.1.	Lokale Datenbank (SQLite)	23
4.4.2.	Cloud-Synchronisation (Firebase)	26
4.5.	UI/UX Architektur	26
4.5.1.	Design System	26
4.5.2.	Cyberpunk-Interface (ObjectDetectCamera)	27
4.6.	Sicherheitsarchitektur	27
4.6.1.	Datenschutz	27
4.6.2.	Authentifizierung	27
4.7.	Wikipedia-Scraping und Automatisierte Übersetzungssysteme	28
4.7.1.	Wikipedia-Bild-Scraping-Pipeline	28
4.7.2.	Massenübersetzungssystem für 30.000+ Arten	30
4.7.3.	CSV-Export und Batch-Verarbeitung	34
4.7.4.	String-Vergleich und Fuzzy-Matching in BirDex	35
4.8.	Performance-Optimierungen	38
4.8.1.	ML-Pipeline Optimierungen	38
4.8.2.	Speicher-Management	38

5. Design-Entscheidungen zur Implementierung	40
5.1. Technologie-Entscheidungen	40
5.1.1. React Native + Expo	40
5.1.2. Machine Learning Integration	40
5.1.3. Datenbank-Architektur	41
5.2. Kamera und Medienverarbeitung	41
5.2.1. Custom Camera Component	41
5.2.2. Bild-Pipeline	42
5.2.3. Performance-Optimierung	42
5.3. Wichtige Implementierungsherausforderungen gelöst	43
5.3.1. Dateiverarbeitung unter Android	43
5.3.2. ML-Modell Integration	43
5.3.3. Echtzeit-Kameraverarbeitung	44
5.4. Unified ML Pipeline Architektur	44
5.4.1. Problem der ursprünglichen Dual-Pipeline	44
5.4.2. Lösung: Sequenzielle Verarbeitung	44
5.4.3. Callback-System für UI-Integration	45
5.5. Audio-ML Pipeline Design	46
5.5.1. WhoBIRD Implementation	46
5.5.2. Dual-Model Inferenz	46
5.6. BirDex Datenbank Design	47
5.6.1. Globale Artenabdeckung	47
5.6.2. Mehrsprachiges Mapping-System	47
5.7. Performance-Monitoring und Debugging	48
5.7.1. Comprehensive Logging System	48
5.7.2. Health Check System	48
6. Ergebnisse	50
6.1. Aktueller Implementierungsstatus	50
6.1.1. Vollständig implementierte Features (nach Teammitglied)	50
6.2. Testing und Evaluierung	53
6.2.1. Entwicklungstests	53
6.2.2. Machine Learning Modell-Validierung	53
6.2.3. Datenbank- und Sync-Tests	54
6.3. Grad der Anforderungserfüllung	55
6.3.1. Status der funktionalen Anforderungen	55
6.3.2. Status der nicht-funktionalen Anforderungen	55
6.4. Performance-Metriken	56
6.4.1. Technische Performance	56
6.4.2. User Experience Metriken	56
6.4.3. Entwicklungsmetriken	56
6.5. Innovative Features und Besonderheiten	56
6.5.1. Unified ML Pipeline	56
6.5.2. Dual-Model Audio System	57
6.5.3. Umfassende Mehrsprachigkeit	57
6.5.4. Species Mapping System	57
6.6. Herausforderungen und Lösungen	58
6.6.1. Technische Herausforderungen überwunden	58

6.6.2.	Windows-Entwicklungsumgebung	58
6.7.	Qualitätssicherung	58
6.7.1.	Code-Qualität	58
6.7.2.	Testing-Strategie	59
7.	Fazit	60
7.1.	Projekterfolg und Auswirkungen	60
7.2.	Wichtige Errungenschaften	60
7.2.1.	Technische Innovation	60
7.2.2.	Entwicklungsexzellenz	61
7.3.	Überwundene Hauptherausforderungen	61
7.3.1.	Technische Herausforderungen	61
7.3.2.	Entwicklungsprozess-Herausforderungen	62
7.4.	Gewonnene Erkenntnisse	63
7.4.1.	Technische Einsichten	63
7.4.2.	Projektmanagement-Einsichten	63
7.5.	Zukünftiges Entwicklungspotential	64
7.5.1.	Langfristige Möglichkeiten	64
7.6.	Bewertung der Unified ML Pipeline	64
7.6.1.	Architektonischer Durchbruch	64
7.6.2.	Performance-Verbesserungen	65
7.6.3.	Wartbarkeit und Skalierbarkeit	65
7.7.	Abschließende Bewertung	65
7.7.1.	Technische Exzellenz	65
7.7.2.	Teamleistung	65
7.7.3.	Innovative Contribution	65
7.7.4.	Zukunftsausblick	66
7.8.	Empfehlungen für zukünftige Entwicklung	66
7.8.1.	Kurzfristige Verbesserungen	66
7.8.2.	Mittelfristige Erweiterungen	66
7.8.3.	Langfristige Vision	66
A.	Technische Spezifikationen	1
A.1.	Systemanforderungen	1
A.2.	ML-Modell Spezifikationen	1
B.	Entwicklungsumgebung Setup	2
B.1.	Voraussetzungen	2
B.2.	Entwicklungskommandos	2
C.	Datenbank-Schema	3
C.1.	SQLite Tabellen	3
D.	API-Endpunkte	4
D.1.	Firebase Firestore Collections	4
E.	Performance-Benchmarks	5
E.1.	ML-Pipeline Performance	5
E.2.	Speichernutzung	5
F.	Konfigurationsoptionen	6
F.1.	App-Konfiguration	6
G.	Troubleshooting Guide	7
G.1.	Häufige Probleme	7

G.2.	Debug-Kommandos	8
H.	Deployment-Anweisungen	8
H.1.	Android APK Build	8
H.2.	iOS Build	8
I.	Lizenz und Credits	9
I.1.	Open Source Lizenzen	9
I.2.	Datenquellen	9
I.3.	Externe Credits	9
8.	Gruppendokumentation und Verantwortlichkeiten	11
A.	Teamzusammensetzung	11
B.	Individuelle Beitrge und Verantwortlichkeiten	11
B.1.	Martin Lauterbach - Projektleiter & Hauptentwickler . .	11
B.2.	Luis Wehrberger - Backend & Cloud-Entwickler	13
B.3.	Younna Samounah - UI/UX Design & Lokalisierung . .	15
C.	Teamarbeit und Kollaboration	16
C.1.	Arbeitsaufteilung	16
C.2.	Kommunikation und Koordination	16
C.3.	Herausforderungen in der Teamarbeit	17
C.4.	Erfolgreiche Kollaborationsaspekte	17
D.	Projektmanagement	17
D.1.	Entwicklungsmethodik	17
D.2.	Meilensteine und Timeline	18
E.	Lernerfahrungen und Reflexion	18
E.1.	Individuelle Lernerfahrungen	18
E.2.	Gemeinsame Lernerfahrungen	19
F.	Empfehlungen fr zukünftige Projekte	19
F.1.	Teamzusammensetzung	19
F.2.	Projektmanagement	19
F.3.	Technische Aspekte	19
G.	Anerkennung und Dank	20

Abbildungsverzeichnis

4.1. Modulare Systemarchitektur von LogChirpy	17
4.2. Unified ML Pipeline Verarbeitungsfluss	19
4.3. Cyberpunk HUD Layout Schema	27
5.1. Echtzeit-Verarbeitungspipeline	44
6.1. Performance-Verbesserungen durch Unified Pipeline	57

Tabellenverzeichnis

4.1. TensorFlow.js Package Performance-Testing	21
4.2. Audio-Pipeline Performance-Profiling	23
6.1. Status der funktionalen Anforderungen	55
6.2. Status der nicht-funktionalen Anforderungen	55
6.3. Technische Performance-Metriken	56
6.4. User Experience Metriken	56
6.5. Entwicklungsmetriken	56
7.1. ML-Pipeline Performance nach Geräteklasse	5
7.2. Speichernutzung nach Komponenten	5
8.1. Arbeitsaufteilung nach Bereichen	16
8.2. Projekt-Timeline und Verantwortlichkeiten	18

1. Einführung und Motivation

1.1. Motivation

LogChirpy ist eine mobile Anwendung, die das Naturerlebnis der Vogelbeobachtung auf ein neues Niveau hebt – sowohl für Anfänger als auch für erfahrene Ornithologen. Die Anwendung ermöglicht eine vielseitige Dokumentation von Vogelbeobachtungen: durch Fotos, Audioaufnahmen von Vogelrufen oder manuelle Eingaben – jeweils optional ergänzt mit GPS-Koordinaten.

1.1.1. Moderne Technologie trifft Naturbeobachtung

LogChirpy verbindet das klassische Hobby der Vogelbeobachtung mit modernen Technologien. Durch die Integration lokaler Machine Learning Modelle können Nutzer Vogelrufe analysieren und automatisch Vogelarten identifizieren. Zusätzlich ist eine optionale lokale Erkennung über TensorFlow.js aktiviert – basierend auf Audio- oder Bilddaten, direkt auf dem Gerät.

Die Integration von OpenStreetMap ermöglicht eine präzise Echtzeit-Geolokalisierung und bietet eine visuelle Übersicht über die eigenen Sichtungen.

1.1.2. Mehrsprachigkeit & Wissenszugang

Die App ist mit vollständiger mehrsprachiger Unterstützung (6 Sprachen: Englisch, Deutsch, Spanisch, Französisch, Ukrainisch und Arabisch) aufgebaut und ermöglicht schnelles Umschalten zwischen Sprachen. Zusätzlich können Nutzer direkt auf den entsprechenden Wikipedia-Artikel einer erkannten Vogelart zugreifen – für sofortige weitere Informationen.

1.1.3. Cloud-Integration & Datenschutz

Für optionale Synchronisation steht Firebase-Konnektivität zur Verfügung:

- Firebase Authentication sichert Login und schützt Nutzerdaten

- Firestore speichert Beobachtungen, Nutzerprofile, Bilder und Standortdaten – wenn der Nutzer dies wünscht
- Nutzung ist auch offline möglich

1.1.4. Medienverarbeitung & Teilen

Aufgenommene Bilder werden automatisch komprimiert und können direkt über das Betriebssystem geteilt werden. Eine besondere Funktion ist die Sticker-Erstellung: erkannte Vögel können aus Bildern ausgeschnitten und als WhatsApp-Sticker exportiert werden – oder für andere Messenger und Bildbearbeitungsapps verfügbar gemacht werden.

1.2. Problemstellung

Die traditionelle Vogelbeobachtung steht vor verschiedenen Herausforderungen:

- **Artenidentifikation:** Viele Vogelarten sind schwer zu unterscheiden, besonders für Anfänger
- **Dokumentation:** Papierbasierte Aufzeichnungen sind unpraktisch und schwer zu organisieren
- **Datenverwaltung:** Keine zentrale Archivierung von Beobachtungen mit Medien
- **Wissenslücken:** Begrenzter Zugang zu Artinformationen im Feld
- **Technologische Barrieren:** Bestehende Apps oft zu komplex oder unvollständig

1.3. Lösungsansatz

LogChirpy adressiert diese Probleme durch einen ganzheitlichen Ansatz:

1.3.1. KI-gestützte Erkennung

- Lokale ML-Modelle für Bild- und Audioanalyse

- Keine Abhängigkeit von Internetverbindung
- Echtzeit-Objekterkennung mit MLKit
- BirdNET-basierte Audioklassifikation

1.3.2. Umfassende Dokumentation

- Multi-modale Eingabe (Foto, Audio, manuell)
- GPS-Integration für Standortdaten
- Lokale SQLite-Datenbank mit Cloud-Sync
- Archivfunktion mit Suchfunktionalität

1.3.3. Benutzerfreundlichkeit

- Intuitive Benutzeroberfläche
- Mehrsprachige Unterstützung
- Dark/Light-Theme
- Barrierefreie Bedienung

1.3.4. Technische Innovation

- React Native für plattformübergreifende Entwicklung
- Expo für vereinfachte Deployment-Prozesse
- Unified ML Pipeline für optimierte Performance
- Modulare Architektur für Wartbarkeit

2. Ziele des Projekts

2.1. Primäre Ziele

2.1.1. Benutzerorientierte Ziele

- **Intuitive mobile App:** Bereitstellung einer benutzerfreundlichen mobilen Anwendung für Vogelbeobachter aller Erfahrungsstufen
- **Präzise Vogelidentifikation:** Ermöglichung akkurater Vogelbestimmung durch multiple Methoden (Audio, visuell, manuell)
- **Umfassendes Archivsystem:** Erstellung eines vollständigen Archivierungssystems für Vogelbeobachtungen
- **KI/ML-Integration:** Integration moderner AI/ML-Technologien für automatisierte Artenerkennung
- **Hybrid-Nutzung:** Unterstützung sowohl für Offline- als auch Cloud-synchronisierte Nutzung

2.1.2. Technische Ziele

- **Cross-Platform Entwicklung:** Entwicklung einer plattformübergreifenden mobilen Anwendung mit React Native und Expo
- **Lokale ML-Modelle:** Implementierung lokaler Machine Learning Modelle für Echtzeit-Vogelerkennung
- **Skalierbare Cloud-Infrastruktur:** Aufbau einer skalierbaren Cloud-Infrastruktur mit Firebase
- **DSGVO-Konformität:** Sicherstellung der DSGVO-Konformität und des Datenschutzes
- **Mehrsprachige Unterstützung:** Bereitstellung vollständiger Lokalisierung in 6 Sprachen (Englisch, Deutsch, Spanisch, Französisch, Ukrai-

nisch, Arabisch)

2.1.3. User Experience Ziele

- **Zugängliche Benutzeroberfläche:** Bereitstellung einer zugänglichen Oberfläche für Nutzer mit unterschiedlicher technischer Expertise
- **Effiziente Protokollierung:** Ermöglichung schneller und effizienter Protokollierung von Vogelsichtungen
- **Rich Media Funktionen:** Bereitstellung umfangreicher Medienfunktionen (Foto, Audio, GPS-Tracking)
- **Social Features:** Unterstützung für Teilen und Community-Features

2.2. Quantitative Anforderungen

2.2.1. Performance-Ziele

- **App-Startzeit:** Hauptbildschirm lädt innerhalb von 2 Sekunden
- **Reaktionszeit:** Benutzeraktionen haben eine Reaktionszeit < 1 Sekunde
- **ML-Verarbeitung:** Audioklassifikation 5 Sekunden pro Clip
- **Bildkompression:** Kompression von Bildern um 30% vor Cloud-Upload

2.2.2. Skalierbarkeits-Ziele

- **Benutzerunterstützung:** Minimum 10 gleichzeitige Benutzer für Datenupload/-zugriff (MVP)
- **Bildkapazität:** Unterstützung für bis zu 1.000 Bilder pro Benutzer
- **Datenbankeinträge:** Minimum 500 manuelle Einträge pro Benutzer
- **Verfügbarkeit:** 80% Uptime (MVP)

2.2.3. Genauigkeits-Ziele

- **Audio-Erkennung:** Vogelerkennung mit 85% Genauigkeit (MVP)
- **GPS-Genauigkeit:** GPS-Koordinaten mit ± 10 Meter Genauigkeit
- **Artendatenbank:** Vollständige Abdeckung von 30.000+ Vogelarten weltweit

2.3. Qualitative Anforderungen

2.3.1. Benutzerfreundlichkeit

- **Intuitive Navigation:** Einfache Navigation mit klaren Anweisungen und Feedback
- **Plattformkonsistenz:** Konsistente Benutzererfahrung zwischen Android und iOS
- **Lernkurve:** Minimale Einarbeitungszeit für neue Benutzer
- **Barrierefreiheit:** Unterstützung für Benutzer mit besonderen Bedürfnissen

2.3.2. Technische Qualität

- **Code-Qualität:** Gut dokumentierter Code nach React Native Best Practices
- **Wartbarkeit:** Modulare Architektur für einfache Wartung und Erweiterung
- **Testabdeckung:** Umfassende Testabdeckung für kritische Komponenten
- **Performance:** Optimierte Performance auf verschiedenen Geräteklassen

2.3.3. Sicherheit und Datenschutz

- **Datenverschlüsselung:** Verschlüsselung von Benutzerdaten bei Übertragung und Speicherung

- **DSGVO-Konformität:** Vollständige Einhaltung der DSGVO-Bestimmungen
- **Lokale Verarbeitung:** ML-Verarbeitung erfolgt lokal für maximalen Datenschutz
- **Optionale Cloud-Nutzung:** Benutzer haben volle Kontrolle über Cloud-Synchronisation

2.4. Erfolgsmetriken

2.4.1. Technische Metriken

- **Funktionale Vollständigkeit:** 95% der geplanten Features implementiert
- **Performance-Benchmarks:** Alle Performance-Ziele erreicht
- **Cross-Platform Kompatibilität:** Erfolgreiche Ausführung auf Android und iOS
- **ML-Modell Genauigkeit:** Erreichen der Zielgenauigkeit für Audio- und Bilderkennung

2.4.2. Benutzer-Metriken

- **Usability Testing:** Positive Bewertung in Benutzerfreundlichkeitstests
- **Feature-Nutzung:** Regelmäßige Nutzung aller Hauptfunktionen
- **Fehlerrate:** Minimale Benutzerfehlerate bei der Navigation
- **Lernzeit:** Kurze Zeit bis zur produktiven Nutzung

3. Anforderungsanalyse

3.1. Nutzungskontext

3.1.1. Feldnutzung

Benutzer werden die App wahrscheinlich im Freien verwenden, in verschiedenen Umgebungen wie Wäldern, Parks oder Naturschutzgebieten. Dabei ist mit variablen Lichtverhältnissen, Hintergrundgeräuschen und begrenzter Internetverbindung zu rechnen.

3.1.2. Datenmanagement

Benutzer greifen auf die App zu, um ihre Vogelbeobachtungsdaten zu verwalten, frühere Sichtungen zu überprüfen und Muster zu analysieren. Die App muss sowohl als Eingabe- als auch als Analysewerkzeug fungieren.

3.1.3. Soziale Interaktion

Benutzer teilen ihre Sichtungen und Bilder mit Freunden, Familie oder anderen Vogelbeobachtern über soziale Medien oder andere Plattformen. Integration mit Standard-Sharing-Mechanismen ist erforderlich.

3.2. Personas

3.2.1. Persona 1: Amateur-Wanderer mit wöchentlichen Touren

Profil:

- **Name:** Jane Doe

- **Alter:** 35
- **Beruf:** Software-Entwicklerin
- **Wandererfahrung:** Fortgeschritten
- **Interessen:** Natur, Vogelbeobachtung, Fotografie
- **Ziele:** Natur genießen, mehr über Vögel lernen, Sichtungen dokumentieren
- **Herausforderungen:** Vogelarten identifizieren, Sichtungen verfolgen, Daten verwalten

User Story: Vogelerkennung und Protokollierung

Als Amateur-Wanderin möchte ich eine Vogelerkennungs-App verwenden, die Vögel anhand ihrer Rufe identifiziert, damit ich meine Sichtungen mit optionalen Bildern und GPS-Koordinaten in meinem Cloud-Archiv protokollieren kann.

Akzeptanzkriterien:

1. Die App kann Vogelarten anhand ihrer Rufe genau identifizieren
2. Die App ermöglicht es Benutzern, Bilder von Vögeln aufzunehmen und hochzuladen
3. Die App protokolliert GPS-Koordinaten von Sichtungen
4. Die App speichert alle Daten in einem für den Benutzer zugänglichen Cloud-Archiv

3.2.2. Persona 2: Langjähriger Hobby-Ornithologe

Profil:

- **Name:** John Smith
- **Alter:** 50
- **Beruf:** Pensionierter Lehrer
- **Ornithologie-Erfahrung:** Fortgeschritten
- **Interessen:** Vogelbeobachtung, Naturschutz, Technologie

- **Ziele:** Effiziente Dokumentation von Vogelbeobachtungen, Zugang zu detaillierten Vogelinformationen, Datenaustausch mit anderen Ornithologen
- **Herausforderungen:** Übergang von traditionellen zu digitalen Methoden, Sicherstellung der Datengenauigkeit, Verwaltung großer Informationsmengen

User Story: Digitales Vogelbeobachtungswerkzeug

Als langjähriger Hobby-Ornithologe möchte ich eine elektronische Alternative für Vogelidentifikation und -protokollierung, damit ich Beobachtungen effizient dokumentieren, detaillierte Vogelinformationen abrufen und Daten mit anderen Ornithologen teilen kann.

Akzeptanzkriterien:

1. Die App bietet genaue Vogelidentifikation durch Stimme
2. Die App ermöglicht es Benutzern, Beobachtungen mit Bildern und GPS-Koordinaten zu protokollieren
3. Die App bietet detaillierte Informationen zu jeder Vogelart
4. Die App ermöglicht Datenaustausch mit anderen Ornithologen
5. Die App speichert alle Daten in einem für den Benutzer zugänglichen Cloud-Archiv

3.3. User Stories

3.3.1. User Story 1: Archivzugriff und Export

Titel: Archivzugriff und Export

Als Amateur-Wanderin möchte ich gelegentlich zum Archiv-Tab wechseln, nach einem schönen Vogelbild suchen und es in andere Apps exportieren, damit ich meine Vogelbeobachtungen mit Freunden und in sozialen Medien teilen kann.

Akzeptanzkriterien:

1. Die App ermöglicht es Benutzern, einfach zum Archiv-Tab zu wechseln
2. Die App bietet eine Suchfunktion zum Finden spezifischer Vogelbilder

3. Die App ermöglicht es Benutzern, Bilder auszuwählen und in andere Apps zu exportieren
4. Die App behält die Bildqualität beim Export bei
5. Die App speichert alle Daten in einem für den Benutzer zugänglichen Cloud-Archiv

3.3.2. User Story 2: Schnelles Teilen kürzlich aufgenommener Bilder

Titel: Schnelles Bildteilen

Als langjähriger Hobby-Ornithologe möchte ich schnell ein kürzlich aufgenommenes Bild teilen, damit ich meine Vogelbeobachtungen sofort mit Freunden und anderen Ornithologen teilen kann.

Akzeptanzkriterien:

1. Die App ermöglicht es Benutzern, schnell auf kürzlich aufgenommene Bilder zuzugreifen
2. Die App bietet eine einfache Teilen-Option direkt aus der Bildansicht
3. Die App unterstützt das Teilen auf mehreren Plattformen (soziale Medien, E-Mail)
4. Die App behält die Bildqualität beim Teilen bei
5. Die App speichert alle Daten in einem für den Benutzer zugänglichen Cloud-Archiv

3.3.3. User Story 3: Standort einer Spatzensichtung finden

Titel: Spatzensichtung finden

Als langjähriger Hobby-Ornithologe möchte ich herausfinden, wo ich einen bestimmten Spatz gesehen habe, damit ich mich an den Ort erinnern und ihn möglicherweise wieder besuchen kann.

Akzeptanzkriterien:

1. Die App ermöglicht es Benutzern, den Karten-Tab zu öffnen

2. Die App bietet eine Filteroption zur Anzeige von Vögeln nach Typ (z.B. Spatz)
3. Die App zeigt Standorte aller Spatzensichtungen auf der Karte
4. Die App ermöglicht es Benutzern, auf einen Standort zu klicken, um Sichtungsdetails anzuzeigen
5. Die App speichert alle Daten in einem für den Benutzer zugänglichen Cloud-Archiv

3.3.4. User Story 4: Erstmalige App-Nutzung

Titel: Erstmalige App-Nutzung

Als neuer Benutzer möchte ich verstehen, wie man die Vogelidentifikations- und Protokollierungs-App verwendet, damit ich effektiv mit der Identifikation und Protokollierung von Vogelbeobachtungen beginnen kann.

Akzeptanzkriterien:

1. Die App bietet ein einladendes Onboarding-Tutorial, das Benutzer durch die Hauptfunktionen führt
2. Die App enthält eine einfache und intuitive Benutzeroberfläche
3. Die App ermöglicht es Benutzern, eine Test-Vogelidentifikation durchzuführen, um sich mit dem Prozess vertraut zu machen
4. Die App erklärt, wie man Sichtungen mit Bildern und GPS-Koordinaten protokolliert
5. Die App zeigt, wie man auf das Archiv zugreift und Sichtungen teilt

3.4. Funktionale Anforderungen

3.4.1. Quantitative Anforderungen

- **Benutzerauthentifizierung:** Unterstützung für mindestens 10 gleichzeitige Benutzer für Datenupload/-zugriff (MVP)

- **Vogeltonenerkennung:** Verarbeitung und Erkennung von Vogelgezwitscher mit 85% Genauigkeit (MVP), 5 Sekunden pro Audioclip
- **Bildkompression:** Kompression von Bildern um 30% vor Cloud-Upload, Unterstützung für bis zu 1.000 Bilder pro Benutzer
- **GPS-Protokollierung:** Erfassung von GPS-Koordinaten mit ± 10 Meter Genauigkeit, optional aktivierbar/deaktivierbar (MVP)
- **Manuelle Protokollierung:** Unterstützung manueller Vogelbeobachtungseinträge mit Artenname, Standort, Notizen; mindestens 500 Einträge pro Benutzer (MVP)
- **Kartenanzeige:** Anzeige aller geolokalisierter Vogelbeobachtungen auf vereinfachter Weltkarte (MVP)

3.4.2. Qualitative Anforderungen

- **Benutzeroberfläche:** Intuitive und benutzerfreundliche Oberfläche, konsistent zwischen Android und iOS (MVP)
- **ML-Integration:** Nahtlose Integration mit angemessener Fehlerbehandlung und aussagekräftigem Feedback (MVP)
- **WhatsApp-Sticker-Erstellung:** Ermöglichung für Benutzer, Vögel in Bildern zu verfolgen und WhatsApp-Sticker zu erstellen
- **Lokale Speicherung & Teilen:** Speicherung von Rohbildern lokal, Bereitstellung von Teilen-Optionen über soziale Medien und Messaging-Apps (MVP)

3.5. Nicht-funktionale Anforderungen

3.5.1. Quantitative Anforderungen

- **Performance:** Laden des Hauptbildschirms innerhalb von 2 Sekunden, Reaktionszeit auf Benutzeraktionen < 1 Sekunde (MVP)
- **Skalierbarkeit:** Backend verarbeitet mehrere gleichzeitige Benutzer ohne Performance-Degradierung
- **Verfügbarkeit:** 80% Uptime (MVP)

3.5.2. Qualitative Anforderungen

- **Sicherheit:** Verschlüsselung von Benutzerdaten bei Übertragung und Speicherung, DSGVO-Konformität (MVP)
- **Kompatibilität:** Kompatibel mit aktuellen Android- und iOS-Versionen, Unterstützung verschiedener Bildschirmgrößen (MVP)
- **Wartbarkeit:** Gut dokumentierter Code nach React Native Best Practices
- **Benutzerfreundlichkeit:** Einfache Navigation mit klaren Anweisungen und Feedback, konsistente Benutzererfahrung (MVP)

3.6. Systemgrenzen und Einschränkungen

3.6.1. Technische Einschränkungen

- **Geräteanforderungen:** Android 8.0+ oder iOS 12.0+
- **Speicherbedarf:** Mindestens 2GB verfügbarer Speicher für ML-Modelle
- **Hardware:** Kamera und Mikrofon erforderlich für vollständige Funktionalität
- **Netzwerk:** Optional für Cloud-Synchronisation, Offline-Betrieb möglich

3.6.2. Regulatorische Einschränkungen

- **Datenschutz:** DSGVO-Konformität erforderlich
- **App Store Richtlinien:** Einhaltung von Google Play und Apple App Store Richtlinien
- **Berechtigungen:** Explizite Benutzereinwilligung für Kamera, Mikrofon und Standort

4. Systemarchitektur und Design

4.1. Systemarchitektur Überblick

LogChirpy wurde mit einer modularen und wartbaren Software-Architektur entwickelt, die moderne plattformübergreifende Entwicklung ermöglicht.

4.1.1. Tech Stack

- **Frontend:** React Native mit Expo für iOS & Android
- **Machine Learning:**
 - TensorFlow.js (Audioanalyse)
 - MLKit (Objekterkennung und Bildklassifikation)
 - BirdNET-Modelle (lokale .tflite-Dateien)
- **Backend/Cloud:**
 - Firebase Authentication (Benutzerverwaltung & Login)
 - Firebase Firestore (Cloud-Datenbank für Benutzer- und Beobachtungsdaten)
- **Karten & Geodaten:** OpenStreetMap über geeignete React Native Wrapper
- **Lokale Datenbank:** SQLite für Offline-Funktionalität

4.1.2. Modulare Struktur

Benutzerverwaltung	Einstellungen & Präferenzen
Authentication (Firebase)	App-Konfiguration
Profileinstellungen	Toggles für Cloud-Sync
Sprachpräferenz	Sprache, Datenschutz, etc.
Beobachtungsprotokollierung	ML & Erkennung
Bild-/Audioaufnahme	Lokale TensorFlow.js-Modelle
Manuelle Protokollierung	MLKit Integration
Offline-Unterstützung	BirdNET Audio-Klassifikation
GPS-Tagging	
Speicher & Sync	Medienverarbeitung
Lokale Speicherung	Wikipedia-Verknüpfung
Firebase Firestore Sync	BirDex-Datenbankintegration
Offline-Modus	Bildkompression und -export

Abb. 4.1.: Modulare Systemarchitektur von LogChirpy

4.1.3. Architekturprinzipien

- **Modulares Design:** Trennung nach Features (z.B. Auth, Observations, AI, Media)
- **Offline-First mit Cloud-Sync:** Daten werden lokal gehalten und bei Bedarf mit der Cloud synchronisiert
- **Trennung von Logik und Präsentation:** UI-Komponenten klar getrennt von API-Aufrufen, Zustandsmanagement und Geschäftslogik
- **Mehrsprachigkeit:** i18n-Integration für internationale Benutzerfreundlichkeit

4.2. Feature-basierte Ordnerstruktur

```

1 /src
2 /app                # Expo Router Screens
3 /log                # Logging-related screens
4 /archive             # Archive and gallery screens
5 /settings            # Settings and preferences
6 /components          # Reusable UI components
7 /contexts            # React contexts
8 /services            # Business logic and API services
9 /hooks               # Custom React hooks

```

```
10 /utils                # Utility functions
11 /locales             # Internationalization files
12 /assets              # Images, models, fonts
13 /constants           # App configuration
```

Codeauszug 4.1: Projektstruktur

Jeder Feature-Ordner enthält:

- `screens/` (Ansichten)
- `components/` (feature-spezifische UI)
- `services/` (Netzwerk- und API-Logik)
- `types.ts` (TypeScript-Definitionen)
- `utils.ts` (Helper-Funktionen)

4.3. Machine Learning Architektur

4.3.1. Unified ML Pipeline

Die Unified ML Pipeline (`/services/unifiedMLPipelineService.ts`) ist ein zentralisierter Orchestrierungsservice, der sowohl Bild- als auch Audio-ML-Verarbeitung in einer einzigen, sequenziellen Pipeline verwaltet.




Abb. 4.2.: Unified ML Pipeline Verarbeitungsfluss

4.3.2. Dual-Model Audio System - Detaillierte Technische Implementierung

Das Audio-Klassifikationssystem basiert auf einer sophisticateden Dual-Model TensorFlow Lite Architektur mit umfangreichem Testing und Optimierung:

Mel-Spektrogramm Verarbeitung und Testing

Spektrogramm-Parameter Testing: Umfangreiche Tests wurden durchgeführt, um optimale Mel-Spektrogramm-Parameter zu finden:

```
1 // Getestete Konfigurationen f r optimale BirdNET
   Performance
2 const melConfigurations = [
3   // Konfiguration 1: Standard BirdNET
4   {
```

```

5     sampleRate: 48000,
6     hopLength: 512,
7     nFft: 1024,
8     nMels: 64,
9     fMin: 150,
10    fMax: 15000,
11    performance: 0.87 // Accuracy achieved
12  },
13  // Konfiguration 2: Optimierte Version
14  {
15    sampleRate: 48000,
16    hopLength: 256,
17    nFft: 2048,
18    nMels: 80,
19    fMin: 200,
20    fMax: 12000,
21    performance: 0.91 // Best performance
22  },
23  // Konfiguration 3: Mobile-optimiert
24  {
25    sampleRate: 48000,
26    hopLength: 1024,
27    nFft: 1024,
28    nMels: 48,
29    fMin: 300,
30    fMax: 10000,
31    performance: 0.84,
32    processingTime: "50% faster" // Trade-off
33  }
34 ];

```

Codeauszug 4.2: Mel-Spektrogramm Konfiguration Testing

Tensor-Preprocessing Pipeline:

```

1  // Detaillierte Tensor-Verarbeitung f r BirdNET
2  const preprocessAudioTensor = async (audioSamples:
3    Float32Array) => {
4    // 1. Resampling auf exakt 48kHz
5    const resampledAudio = await resampleAudio(audioSamples
6      , targetSampleRate);
7
8    // 2. Windowing mit Hann-Fenster
9    const windowedAudio = applyHannWindow(resampledAudio);
10
11    // 3. STFT (Short-Time Fourier Transform)
12    const stft = computeSTFT(windowedAudio, {
13      nFft: 1024,
14      hopLength: 512,
15      window: 'hann'
16    });
17  };

```

```

16 // 4. Mel-Filter Bank Application
17 const melSpectrogram = applyMelFilterBank(stft, {
18   nMels: 64,
19   fMin: 150,
20   fMax: 15000,
21   sampleRate: 48000
22 });
23
24 // 5. Logarithmische Skalierung
25 const logMelSpec = melSpectrogram.map(frame =>
26   frame.map(value => Math.log(Math.max(value, 1e-10)))
27 );
28
29 // 6. Normalisierung [-1, 1]
30 const normalizedSpec = normalizeSpectrogram(logMelSpec)
31   ;
32
33 // 7. Tensor-Formatierung f r TFLite
34 const inputTensor = tf.tensor4d(
35   normalizedSpec,
36   [1, 288, 64, 1], // [batch, time, frequency, channels
37   ]
38   'float32'
39 );
40
41 return inputTensor;
42 };

```

Codeauszug 4.3: Audio Tensor Preprocessing

TensorFlow.js Package Testing und Optimierung

Package-Kompatibilitäts-Matrix: Extensive Tests wurden mit verschiedenen TensorFlow.js Paketen durchgeführt:

Package	Version	Performance	Memory	Kompatibilität
@tensorflow/tfjs	4.15.0	Langsam	Hoch	React Native
@tensorflow/tfjs-react-native	0.8.0	Mittel	Mittel	Gut
@tensorflow/tfjs-platform-react-native	0.66.0	Schnell	Niedrig	Optimal
react-native-fast-tfjs	1.0.0	Sehr schnell	Sehr niedrig	Perfekt

Tab. 4.1.: TensorFlow.js Package Performance-Testing

Optimierte TFLite Integration:

```

1 // Finale optimierte TFLite-Integration
2 import { TensorFlowModel } from 'react-native-fast-tfjs';

```

```
3
4 class BirdNETClassifier {
5     private primaryModel: TensorflowModel;
6     private metaModel: TensorflowModel;
7
8     async initialize() {
9         // Modell-Loading mit optimierten Parametern
10        this.primaryModel = await TensorflowModel.
11            loadFromBundle({
12                modelPath: 'BirdNET_GLOBAL_6K_V2.4_Model_FP32.
13                    tflite',
14                numThreads: 4, // Optimiert f r mobile CPUs
15                useGPU: false, // CPU f r Konsistenz
16                useNNAPI: true // Android Neural Networks API
17            });
18
19        this.metaModel = await TensorflowModel.loadFromBundle
20            ({
21                modelPath: 'BirdNET_GLOBAL_6K_V2.4_MData_Model_FP16
22                    .tflite',
23                numThreads: 2,
24                useGPU: false,
25                useNNAPI: true
26            });
27    }
28
29    async classify(audioTensor: tf.Tensor, location?:
30        Location) {
31        // Prim r-Modell Inferenz
32        const primaryResults = await this.primaryModel.
33            predict(audioTensor);
34
35        // Meta-Modell Enhancement (falls Location verf gbar
36        )
37        if (location) {
38            const weekOfYear = this.calculateWeekOfYear(new
39                Date());
40            const weekCosine = Math.cos(2 * Math.PI *
41                weekOfYear / 52);
42
43            const metaInput = tf.tensor2d([[
44                location.latitude / 90.0, // Normalisiert [-1,
45                    1]
46                location.longitude / 180.0, // Normalisiert [-1,
47                    1]
48                weekCosine
49            ]]);
50
51            const metaResults = await this.metaModel.predict(
52                metaInput);
53        }
```

```
42     // Probability Blending (30% Meta-Einfluss)
43     const blendedResults = this.blendPredictions(
44         primaryResults,
45         metaResults,
46         0.3
47     );
48
49     return blendedResults;
50 }
51
52     return primaryResults;
53 }
54 }
```

Codeauszug 4.4: Fast TFLite Implementation

Audio-Pipeline Performance-Metriken

Processing Step	Duration (ms)	Memory (MB)	CPU (%)
Audio Loading	50-100	5	10
Resampling	100-200	8	25
STFT Computation	200-400	12	45
Mel-Filter Application	150-300	6	30
Tensor Conversion	50-100	10	15
Model Inference	300-800	25	60
Post-processing	50-100	3	10
Total Pipeline	900-2000	69	Peak: 60

Tab. 4.2.: Audio-Pipeline Performance-Profiling

4.4. Datenarchitektur

4.4.1. Lokale Datenbank (SQLite)

```
1  -- Haupttabelle f r Vogelbeobachtungen
2  CREATE TABLE observations (
3      id INTEGER PRIMARY KEY AUTOINCREMENT,
4      uuid TEXT UNIQUE NOT NULL,
5      species_name TEXT,
6      common_name TEXT,
7      scientific_name TEXT,
8      confidence REAL,
9      timestamp TEXT NOT NULL,
10     latitude REAL,
11     longitude REAL,
12     altitude REAL,
```

```

13     accuracy REAL,
14     image_path TEXT,
15     audio_path TEXT,
16     video_path TEXT,
17     notes TEXT,
18     weather_condition TEXT,
19     temperature REAL,
20     detection_method TEXT, -- 'manual', 'image_ml', '
        audio_ml'
21     ml_model_version TEXT,
22     device_info TEXT,
23     app_version TEXT,
24     sync_status INTEGER DEFAULT 0, -- 0=local, 1=syncing,
        2=synced
25     created_at TEXT DEFAULT CURRENT_TIMESTAMP,
26     updated_at TEXT DEFAULT CURRENT_TIMESTAMP,
27     deleted_at TEXT NULL
28 );
29
30 -- BirDex vollst ndige Spezies-Datenbank (30,000+ Arten)
31 CREATE TABLE species (
32     id INTEGER PRIMARY KEY,
33     scientific_name TEXT UNIQUE NOT NULL,
34     common_name_en TEXT,
35     common_name_de TEXT,
36     common_name_es TEXT,
37     common_name_fr TEXT,
38     common_name_uk TEXT,
39     common_name_ar TEXT,
40     family_name TEXT,
41     order_name TEXT,
42     iucn_status TEXT,
43     wikipedia_url TEXT,
44     wikipedia_image_url TEXT,
45     macaulay_asset_url TEXT,
46     ebird_code TEXT,
47     habitat_description TEXT,
48     geographic_range TEXT,
49     migration_pattern TEXT,
50     breeding_season TEXT,
51     average_length_cm REAL,
52     average_wingspan_cm REAL,
53     average_weight_g REAL,
54     created_at TEXT DEFAULT CURRENT_TIMESTAMP,
55     updated_at TEXT DEFAULT CURRENT_TIMESTAMP
56 );
57
58 -- Benutzereinstellungen
59 CREATE TABLE user_settings (
60     id INTEGER PRIMARY KEY,
61     key TEXT UNIQUE NOT NULL,

```



```
62     value TEXT,
63     data_type TEXT, -- 'string', 'number', 'boolean', '
        json'
64     updated_at TEXT DEFAULT CURRENT_TIMESTAMP
65 );
66
67 -- ML-Pipeline Cache f r Performance
68 CREATE TABLE ml_cache (
69     id INTEGER PRIMARY KEY AUTOINCREMENT,
70     file_hash TEXT UNIQUE NOT NULL,
71     file_type TEXT, -- 'image', 'audio'
72     ml_results TEXT, -- JSON-encoded results
73     model_version TEXT,
74     confidence REAL,
75     processing_time_ms INTEGER,
76     created_at TEXT DEFAULT CURRENT_TIMESTAMP
77 );
78
79 -- Sync-Log f r Cloud-Synchronisation
80 CREATE TABLE sync_log (
81     id INTEGER PRIMARY KEY AUTOINCREMENT,
82     table_name TEXT NOT NULL,
83     record_id TEXT NOT NULL,
84     action TEXT NOT NULL, -- 'create', 'update', 'delete'
85     local_timestamp TEXT DEFAULT CURRENT_TIMESTAMP,
86     cloud_timestamp TEXT,
87     status TEXT DEFAULT 'pending', -- 'pending', 'success
        ', 'error'
88     error_message TEXT,
89     retry_count INTEGER DEFAULT 0
90 );
91
92 -- Indizes f r Performance-Optimierung
93 CREATE INDEX idx_observations_scientific_name ON
        observations(scientific_name);
94 CREATE INDEX idx_observations_timestamp ON observations(
        timestamp);
95 CREATE INDEX idx_observations_sync_status ON observations
        (sync_status);
96 CREATE INDEX idx_species_scientific_name ON species(
        scientific_name);
97 CREATE INDEX idx_species_common_names ON species(
        common_name_en, common_name_de, common_name_es);
98 CREATE INDEX idx_ml_cache_hash ON ml_cache(file_hash);
99 CREATE INDEX idx_sync_log_status ON sync_log(status);
```

Codeauszug 4.5: Vollständiges SQLite Schema

4.4.2. Cloud-Synchronisation (Firebase)

- **Firestore Collections:**
 - **users/** - Benutzerprofile und Einstellungen
 - **observations/** - Vogelbeobachtungen mit Metadaten
 - **media/** - Referenzen zu Firebase Storage Dateien
- **Firebase Storage:** Bild- und Audiodateien
- **Sync-Strategie:** Offline-first mit optionaler Cloud-Synchronisation

4.5. UI/UX Architektur

4.5.1. Design System

- **Theming:** Dark/Light Mode mit dynamischem Umschalten
- **Komponenten:** Wiederverwendbare UI-Komponenten mit konsistenter Stilrichtlinie
- **Navigation:** Tab-basierte Navigation mit Stack-Navigation für Details
- **Feedback:** Haptisches Feedback und Audiohinweise für Aktionen

4.5.2. Cyberpunk-Interface (ObjectDetectCamera)

```
NEURAL VISION SYSTEM

Visual Analysis:
  95% - Turdus migratorius
  80% - Corvus brachyrhynchos

Audio Analysis:
  92% - American Robin
  75% - Blue Jay

[SVG OVERLAYS]
  Echtzeiterkennungsboxen
  mit Konfidenz-Farbkodierung
```

Abb. 4.3.: Cyberpunk HUD Layout Schema

4.6. Sicherheitsarchitektur

4.6.1. Datenschutz

- **Lokale Verarbeitung:** Alle ML-Operationen erfolgen auf dem Gerät
- **Optionale Cloud-Nutzung:** Benutzer entscheiden über Cloud-Synchronisation
- **Verschlüsselung:** Daten bei Übertragung und Speicherung verschlüsselt
- **DSGVO-Konformität:** Vollständige Einhaltung der Datenschutzbestimmungen

4.6.2. Authentifizierung

- **Firebase Auth:** Sichere Benutzerauthentifizierung
- **Lokaler Fallback:** App funktioniert ohne Anmeldung
- **Berechtigungen:** Explizite Einwilligung für Kamera, Mikrofon, Standort

4.7. Wikipedia-Scraping und Automatisierte Übersetzungssysteme

4.7.1. Wikipedia-Bild-Scraping-Pipeline

Umfassendes Scraping-System für 30.000+ Vogelarten:

```
1 // Vollautomatisiertes Wikipedia-Scraping f r alle
  Vogelarten
2 class WikipediaScrapingService {
3   private readonly RATE_LIMIT = 100; // Requests per
    minute
4   private readonly RETRY_ATTEMPTS = 3;
5   private readonly USER_AGENT = 'LogChirpy/1.0 (
    Educational Research)';
6
7   async scrapeAllBirdImages(speciesList: Species[]) {
8     const results = [];
9     const rateLimiter = new RateLimiter(this.RATE_LIMIT);
10
11     for (const species of speciesList) {
12       await rateLimiter.wait();
13
14       try {
15         // Multi-Language Wikipedia Scraping
16         const imageData = await this.scrapeSpeciesImages(
            species);
17         results.push(imageData);
18
19         // Progress tracking
20         console.log('Scraped ${results.length}/${{
            speciesList.length}: ${species.scientific_name
            }');
21
22       } catch (error) {
23         console.error('Failed to scrape ${species.
            scientific_name}:', error);
24         // Retry mechanism
25         await this.retryWithBackoff(species, error);
26       }
27     }
28
29     return results;
30   }
31
32   async scrapeSpeciesImages(species: Species) {
33     // 1. Prim re Wikipedia-Suche (Englisch)
34     let imageUrl = await this.searchWikipediaImage(
        species.scientific_name, 'en'
```

```
36     );
37
38     // 2. Fallback auf Common Name Search
39     if (!imageUrl && species.common_name_en) {
40         imageUrl = await this.searchWikipediaImage(
41             species.common_name_en, 'en'
42         );
43     }
44
45     // 3. Multi-Language Fallback
46     if (!imageUrl) {
47         const languages = ['de', 'es', 'fr'];
48         for (const lang of languages) {
49             const commonName = species['common_name_${lang}'];
50             if (commonName) {
51                 imageUrl = await this.searchWikipediaImage(
52                     commonName, lang);
53                 if (imageUrl) break;
54             }
55         }
56
57         // 4. Wikimedia Commons Search
58         if (!imageUrl) {
59             imageUrl = await this.searchWikimediaCommons(
60                 species.scientific_name);
61         }
62
63         // 5. Quality validation
64         if (imageUrl) {
65             const isValid = await this.validateImageQuality(
66                 imageUrl);
67             if (!isValid) {
68                 imageUrl = await this.findAlternativeImage(
69                     species);
70             }
71         }
72
73         return {
74             scientific_name: species.scientific_name,
75             image_url: imageUrl,
76             source: 'wikipedia',
77             scraped_at: new Date().toISOString(),
78             quality_score: await this.calculateImageQuality(
79                 imageUrl)
80         };
81     }
82 }
83
84 private async searchWikipediaImage(query: string,
85     language: string) {
```

```
80     const apiUrl = `https://${language}.wikipedia.org/api
      /rest_v1/page/summary/${encodeURIComponent(query)}
      `;
81
82     const response = await fetch(apiUrl, {
83       headers: { 'User-Agent': this.USER_AGENT }
84     });
85
86     if (response.ok) {
87       const data = await response.json();
88       return data.thumbnail?.source || data.originalimage
        ?.source;
89     }
90
91     return null;
92   }
93
94   private async searchWikimediaCommons(scientificName:
     string) {
95     const apiUrl = `https://commons.wikimedia.org/w/api.
       php`;
96     const params = new URLSearchParams({
97       action: 'query',
98       format: 'json',
99       list: 'search',
100      srsearch: `${scientificName} bird`,
101      srnamespace: '6', // File namespace
102      srlimit: '10'
103    });
104
105     const response = await fetch(`${apiUrl}?${params}`);
106     const data = await response.json();
107
108     if (data.query?.search?.length > 0) {
109       // Return highest quality image
110       return await this.getCommonsImageUrl(data.query.
        search[0].title);
111     }
112
113     return null;
114   }
115 }
```

Codeauszug 4.6: Wikipedia Scraping Implementation

4.7.2. Massenübersetzungssystem für 30.000+ Arten

Multi-API Translation Pipeline mit Fallback-Strategien:

```
1 // Umfassendes Übersetzungssystem mit mehreren API-
  Fallbacks
2 class MassTranslationService {
3   private translationAPIs = [
4     { name: 'DeepL', quota: 500000, cost: 'low' },
5     { name: 'Google Translate', quota: 100000, cost: '
      medium' },
6     { name: 'Microsoft Translator', quota: 2000000, cost:
      'free' },
7     { name: 'LibreTranslate', quota: 'unlimited', cost: '
      free' }
8   ];
9
10  async translateAllSpecies(species: Species[],
    targetLanguages: string[]) {
11    const translationBatches = this.createBatches(species
      , 100); // Batch processing
12    const results = [];
13
14    for (const batch of translationBatches) {
15      console.log('Processing batch ${results.length +
        1}/${translationBatches.length}');
16
17      const batchResults = await Promise.allSettled(
18        batch.map(sp => this.translateSpecies(sp,
          targetLanguages))
19      );
20
21      results.push(...batchResults);
22
23      // Rate limiting zwischen Batches
24      await this.delay(1000);
25    }
26
27    return this.processBatchResults(results);
28  }
29
30  async translateSpecies(species: Species, languages:
    string[]) {
31    const translations = { scientific_name: species.
      scientific_name };
32
33    for (const lang of languages) {
34      if (species['common_name_${lang}']) {
35        // Bereits vorhanden, überspringen
36        translations['common_name_${lang}'] = species['
          common_name_${lang}'];
37        continue;
38      }
39
40      try {
```

```
41 // Prim re   bersetzung   von Englisch
42 let translation = await this.
    translateWithFallback(
43     species.common_name_en,
44     'en',
45     lang
46 );
47
48 // Validierung der   bersetzung
49 if (!this.isValidBirdName(translation, lang)) {
50     // Fallback: Wissenschaftlicher Name +
        Sprachspezifische Suffixe
51     translation = await this.generateLocalizedName(
52         species.scientific_name,
53         lang
54     );
55 }
56
57 translations['common_name_${lang}'] = translation
    ;
58
59 } catch (error) {
60     console.error('Translation failed for ${species.
        scientific_name} to ${lang}:', error);
61     // Fallback: Behalte englischen Namen
62     translations['common_name_${lang}'] = species.
        common_name_en;
63 }
64 }
65
66 return translations;
67 }
68
69 private async translateWithFallback(text: string, from:
    string, to: string) {
70     for (const api of this.translationAPIs) {
71         try {
72             if (this.hasQuotaRemaining(api)) {
73                 const translation = await this.
                    callTranslationAPI(api, text, from, to);
74                 if (translation && translation !== text) {
75                     this.updateQuotaUsage(api);
76                     return translation;
77                 }
78             }
79         } catch (error) {
80             console.warn(`${api.name} failed, trying next API
                :', error);
81         }
82     }
83 }
```



```
84 // Letzte Fallback-Option: Regel-basierte
    bersetzung
85 return await this.ruleBasedTranslation(text, to);
86 }
87
88 private async ruleBasedTranslation(englishName: string,
    targetLang: string) {
89 // Sprachspezifische Transformationsregeln
90 const rules = {
91   'de': {
92     patterns: [
93       { from: /(.) Warbler$/, to: '$1-Walds nger '
94         },
95       { from: /(.) Flycatcher$/, to: '$1-
          Fliegenschn pper ' },
96       { from: /(.) Hawk$/, to: '$1-Falke' },
97       { from: /(.) Owl$/, to: '$1-Eule' }
98     ],
99     fallback: name => '${name} (Vogel)'
100   },
101   'es': {
102     patterns: [
103       { from: /(.) Warbler$/, to: 'Reinita $1' },
104       { from: /(.) Flycatcher$/, to: 'Papamoscas $1'
105         },
106       { from: /(.) Hawk$/, to: 'Halc n $1' }
107     ],
108     fallback: name => '${name} (ave)'
109   }
110   // ... weitere Sprachen
111 };
112
113 const langRules = rules[targetLang];
114 if (!langRules) return englishName;
115
116 // Pattern-Matching anwenden
117 for (const rule of langRules.patterns) {
118   if (rule.from.test(englishName)) {
119     return englishName.replace(rule.from, rule.to);
120   }
121 }
122
123 // Fallback-Regel
124 return langRules.fallback(englishName);
125 }
```

Codeauszug 4.7: Automated Translation System

4.7.3. CSV-Export und Batch-Verarbeitung

Effiziente Verarbeitung großer Datensätze:

```

1 // CSV-basierte    bersetzungsverarbeitung    f r 30k+
   Eintr ge
2 class CSVTranslationProcessor {
3   async processTranslationCSV(inputPath: string,
   outputPath: string) {
4     const csvData = await this.loadCSV(inputPath);
5     const processedData = [];
6
7     console.log('Processing ${csvData.length} species
   translations...');
8
9     // Chunk-Processing f r Memory-Effizienz
10    const chunkSize = 1000;
11    for (let i = 0; i < csvData.length; i += chunkSize) {
12      const chunk = csvData.slice(i, i + chunkSize);
13
14      const processedChunk = await Promise.allSettled(
15        chunk.map(row => this.processSpeciesRow(row))
16      );
17
18      // Erfolgreich verarbeitete Eintr ge sammeln
19      const successfulResults = processedChunk
20        .filter(result => result.status === 'fulfilled')
21        .map(result => result.value);
22
23      processedData.push(...successfulResults);
24
25      // Progress Report
26      console.log('Processed ${Math.min(i + chunkSize,
   csvData.length)}/${csvData.length} entries');
27
28      // Memory Cleanup
29      if (processedData.length % 5000 === 0) {
30        await this.flushToFile(processedData, outputPath,
   'append');
31        processedData.length = 0; // Clear array
32      }
33    }
34
35    // Final flush
36    if (processedData.length > 0) {
37      await this.flushToFile(processedData, outputPath, '
   append');
38    }
39
40    console.log('CSV processing completed successfully');
41  }

```

```

42
43 private async processSpeciesRow(row: any) {
44     return {
45         id: row.id,
46         scientific_name: row.scientific_name,
47         common_name_en: this.cleanBirdName(row.
            common_name_en),
48         common_name_de: this.cleanBirdName(row.
            common_name_de),
49         common_name_es: this.cleanBirdName(row.
            common_name_es),
50         common_name_fr: this.cleanBirdName(row.
            common_name_fr),
51         common_name_uk: this.cleanBirdName(row.
            common_name_uk),
52         common_name_ar: this.cleanBirdName(row.
            common_name_ar),
53         translation_quality: this.assessTranslationQuality(
            row),
54         updated_at: new Date().toISOString()
55     };
56 }
57
58 private cleanBirdName(name: string): string {
59     if (!name) return '';
60
61     return name
62         .trim()
63         .replace(/\s+/g, ' ') // Normalize whitespace
64         .replace(/[^\w\s\-\(\)]/g, '') // Remove special
            chars
65         .replace(/\b(bird|vogel|ave|oiseau|
            )\b/gi, '') // Remove generic terms
66         .trim();
67 }
68 }

```

Codeauszug 4.8: CSV Translation Processing

4.7.4. String-Vergleich und Fuzzy-Matching in BirDex

Robuste Artenerkennung mit fortgeschrittenen String-Algorithmen:

```

1 // Erweiterte String-Vergleichsalgorithmen f r BirDex-
    Suche
2 class SpeciesStringMatcher {
3
4     async findBestMatch(query: string, language: string = '
        en'): Promise<Species | null> {
5         // 1. Exakte bereinstimmung (schnellster Pfad)

```

```
6   let match = await this.exactMatch(query, language);
7   if (match) return match;
8
9   // 2. Normalisierte Suche
10  match = await this.normalizedMatch(query, language);
11  if (match) return match;
12
13  // 3. Subspecies-Fallback
14  match = await this.subspeciesFallback(query, language
15  );
16  if (match) return match;
17
18  // 4. Fuzzy-Matching mit verschiedenen Algorithmen
19  match = await this.fuzzyMatch(query, language);
20  if (match) return match;
21
22  // 5. Cross-Language-Suche
23  match = await this.crossLanguageSearch(query);
24  if (match) return match;
25
26  return null;
27 }
28
29 private async fuzzyMatch(query: string, language:
30   string): Promise<Species | null> {
31   const candidates = await this.getAllSpeciesNames(
32     language);
33   let bestMatch = null;
34   let bestScore = 0;
35
36   for (const candidate of candidates) {
37     // Multiple Similarity-Algorithmen kombinieren
38     const levenshteinScore = this.levenshteinSimilarity
39       (query, candidate.name);
40     const jaccardScore = this.jaccardSimilarity(query,
41       candidate.name);
42     const jaroWinklerScore = this.jaroWinklerSimilarity
43       (query, candidate.name);
44     const phoneticScore = this.phoneticSimilarity(query
45       , candidate.name);
46
47     // Gewichtete Kombination der Scores
48     const combinedScore = (
49       levenshteinScore * 0.3 +
50       jaccardScore * 0.2 +
51       jaroWinklerScore * 0.3 +
52       phoneticScore * 0.2
53     );
54
55     if (combinedScore > bestScore && combinedScore >
56       0.7) {
```

```
49         bestScore = combinedScore;
50         bestMatch = candidate;
51     }
52 }
53
54     return bestMatch ? await this.getSpeciesByName(
55         bestMatch.name) : null;
56 }
57
58 private levenshteinSimilarity(a: string, b: string):
59     number {
60     const distance = this.levenshteinDistance(a.
61         toLowerCase(), b.toLowerCase());
62     const maxLength = Math.max(a.length, b.length);
63     return maxLength === 0 ? 1 : (maxLength - distance) /
64         maxLength;
65 }
66
67 private jaccardSimilarity(a: string, b: string): number
68 {
69     const setA = new Set(a.toLowerCase().split(''));
70     const setB = new Set(b.toLowerCase().split(''));
71     const intersection = new Set([...setA].filter(x =>
72         setB.has(x)));
73     const union = new Set([...setA, ...setB]);
74     return intersection.size / union.size;
75 }
76
77 private jaroWinklerSimilarity(a: string, b: string):
78     number {
79     // Implementierung des Jaro-Winkler-Algorithmus
80     const jaroSim = this.jaroSimilarity(a, b);
81     if (jaroSim < 0.7) return jaroSim;
82
83     // Berechne gemeinsame Prefix-Länge (max 4 Zeichen)
84     let prefixLength = 0;
85     for (let i = 0; i < Math.min(a.length, b.length, 4);
86         i++) {
87         if (a[i].toLowerCase() === b[i].toLowerCase()) {
88             prefixLength++;
89         } else {
90             break;
91         }
92     }
93
94     return jaroSim + (0.1 * prefixLength * (1 - jaroSim))
95         ;
96 }
97
98 private phoneticSimilarity(a: string, b: string):
99     number {
```

```
90 // Soundex- hnlicher phonetischer Vergleich f r
    Vogelnamen
91 const phoneticA = this.generatePhoneticCode(a);
92 const phoneticB = this.generatePhoneticCode(b);
93 return phoneticA === phoneticB ? 1 : 0;
94 }
95
96 private async crossLanguageSearch(query: string):
    Promise<Species | null> {
97     const languages = ['en', 'de', 'es', 'fr', 'uk', 'ar
        '];
98
99     for (const lang of languages) {
100         const match = await this.fuzzyMatch(query, lang);
101         if (match) {
102             console.log('Cross-language match found in ${lang
                }');
103             return match;
104         }
105     }
106
107     return null;
108 }
109 }
```

Codeauszug 4.9: Advanced String Matching for Species

4.8. Performance-Optimierungen

4.8.1. ML-Pipeline Optimierungen

- **Sequenzielle Verarbeitung:** Vermeidung von Race Conditions
- **Qualitätsreduzierung:** 0.3 Qualität für ML-Verarbeitung
- **Ergebnis-Begrenzung:** Top 2 Ergebnisse pro Kategorie angezeigt
- **Konfigurierbare Delays:** Anpassbare Zykluszeiten für verschiedene Geräte

4.8.2. Speicher-Management

- **Automatische Bereinigung:** Temporäre Dateien werden automatisch gelöscht

- **Lazy Loading:** ML-Modelle werden bei Bedarf geladen
- **Pagination:** Datenbankabfragen mit Seiteneinteilung (20 Elemente pro Seite)
- **Bildkompression:** Automatische Kompression vor Upload (30

5. Design-Entscheidungen zur Implementierung

5.1. Technologie-Entscheidungen

5.1.1. React Native + Expo

Begründung: Plattformübergreifende Entwicklung mit nativer Performance

Vorteile:

- Gemeinsame Codebasis für iOS und Android
- Umfangreiches Ökosystem und Community-Support
- Schnelle Entwicklungszyklen mit Hot Reload
- Native Module Integration möglich

Herausforderung: Erforderlicher Übergang von ExpoGo zu Custom Dev Client für ML-Modell-Unterstützung, User Stories und Benutzer-Algorithmus-Kontrolle

5.1.2. Machine Learning Integration

Lokale Verarbeitung: TensorFlow.js und MLKit für Offline-Objekterkennung, Vogelbild- und Audioklassifikation

Vorteile:

- Datenschutz durch lokale Verarbeitung
- Keine Abhängigkeit von Internetverbindung
- Niedrige Latenz bei Echtzeitverarbeitung

- Keine API-Kosten für ML-Operationen

Custom Models: Konvertierung von Vogelklassifikationsmodellen zu .tflite-Format für optimierte mobile Performance

5.1.3. Datenbank-Architektur

Hybrid-Ansatz: Kombination aus lokaler SQLite und Firebase Cloud-Synchronisation

- **Lokale Speicherung:** SQLite für Offline-Fähigkeit und schnellen Zugriff
- **Cloud-Sync:** Firebase Firestore für geräteübergreifende Synchronisation
- **Offline-First:** Lokale Datenbank als primäre Quelle mit optionalem Cloud-Backup

Vorteile:

- Vollständige Offline-Funktionalität
- Geräteübergreifende Datensynchronisation
- Benutzer kontrolliert Cloud-Nutzung
- Ausfallsicherheit bei Netzwerkproblemen

5.2. Kamera und Medienverarbeitung

5.2.1. Custom Camera Component

Integration mit MLKit für Echtzeit-Objekterkennung und Bildklassifikation sowie sequenzielle Audioverarbeitung und -klassifikation mit custom .tflite-Modellen.

Design-Entscheidungen:

- **Vision Camera Package:** react-native-vision-camera für erweiterte Kamera-Kontrolle
- **MLKit Integration:** @infinitered/react-native-mlkit-* Pakete für zuverlässige ML-Operations

- **Unified Pipeline:** Sequenzielle Verarbeitung zur Vermeidung von Race Conditions

5.2.2. Bild-Pipeline

Asynchrone Verarbeitung mit temporärer Dateiverarbeitung für ML-Analyse:

```
1 const imageProcessingPipeline = async () => {
2   // 1. Foto aufnehmen mit reduzierter Qualität für ML
3   const photo = await camera.takePicture({ quality: 0.3
4     });
5
6   // 2. Objekterkennung mit MLKit
7   const detections = await detectObjects(photo.path);
8
9   // 3. Für jede Erkennung: Zuschneiden und
10  Klassifizieren
11  for (const detection of detections) {
12    const croppedImage = await cropImage(photo.path,
13      detection.frame);
14    const classification = await classifyBird(
15      croppedImage);
16
17    // 4. High-Confidence Erkennungen speichern
18    if (classification.confidence > 0.7) {
19      await saveBirdObservation(classification, detection
20        );
21    }
22  }
23 }
```

Codeauszug 5.1: Bild-Pipeline Design

5.2.3. Performance-Optimierung

Strategie: Umfangreiche try-catch-Blöcke, useState-Management, temporäre Datei-Bereinigung

Ergebnis: Reibungslose Funktionsweise auf Android-Geräten ab 2020+ (Low-End bis High-End)

5.3. Wichtige Implementierungsherausforderungen gelöst

5.3.1. Dateiverarbeitung unter Android

Problem: ExpoGo Build unterstützt keine Dateiverarbeitung

Lösung: Custom Dev Client Build mit umfangreichem asynchronem Error Handling

```
1 const processFileWithFallback = async (filePath: string)
2   => {
3     try {
4       // Primärer Verarbeitungsweg
5       const result = await processFile(filePath);
6       return result;
7     } catch (error) {
8       console.warn('Primary processing failed:', error);
9
10      try {
11        // Fallback-Verarbeitung
12        const fallbackResult = await processFileAlternative
13          (filePath);
14        return fallbackResult;
15      } catch (fallbackError) {
16        console.error('All processing methods failed:',
17          fallbackError);
18        throw new Error('File processing unavailable');
19      }
20    } finally {
21      // Cleanup temporärer Dateien
22      await cleanupTemporaryFiles();
23    }
24  };
25
```

Codeauszug 5.2: Error Handling Strategie

5.3.2. ML-Modell Integration

Problem: Veraltete React Native Pakete für ML-Operationen

Lösung: Gut gewartete MLKit-Pakete von denselben Entwicklern gefunden

Verwendete Pakete:

- @infinitered/react-native-mlkit-object-detection

- @infinitered/react-native-mlkit-image-labeling
- Custom TensorFlow.js Integration für Audio

5.3.3. Echtzeit-Kameraverarbeitung

Problem: ML-Modelle können frameProcessing nicht direkt verarbeiten

Lösung: Asynchrone Bild-Speicherung → Objekterkennung → Bild-Zuschnitt → Klassifikations-Pipeline

```
Kamera Frame → Bild speichern (temp) → MLKit Objekterkennung
↓
Erkannte Objekte → Bild zuschneiden → Vogelklassifikation
↓
Klassifikationsergebnisse → UI Update → Cleanup temp files
```

Abb. 5.1.: Echtzeit-Verarbeitungspipeline

5.4. Unified ML Pipeline Architektur

5.4.1. Problem der ursprünglichen Dual-Pipeline

- **Race Conditions:** Separate Bild- und Audio-Verarbeitungsschleifen verursachen Ressourcenkonflikte
- **Datei-Stabilitätsprobleme:** "Datei-Stabilitäts-Timeout nach 3000ms" Fehler
- **Audio-Aufnahme-Konflikte:** "Nur ein Recording-Objekt kann gleichzeitig vorbereitet werden"
- **Ressourcenerschöpfung:** Multiple simultane ML-Operationen überlasteten Geräteressourcen

5.4.2. Lösung: Sequenzielle Verarbeitung

Die unified pipeline verarbeitet ML-Operationen sequenziell in einer kontrollierten Schleife:

```
1 class UnifiedMLPipelineService {
2   async runPipelineCycle() {
3     try {
```

```
4      // === BILDVERARBEITUNGSPHASE ===
5      this.updateState('capturing_image');
6      await this.processImagePhase();
7
8      // Kleine Pause zwischen Phasen
9      await this.delay(100);
10
11     // === AUDIOVERARBEITUNGSPHASE ===
12     if (this.config.hasAudioPermission) {
13         this.updateState('recording_audio');
14         await this.processAudioPhase();
15     }
16
17     // === WARTEPHASE ===
18     this.updateState('waiting');
19     await this.delay(Config.camera.pipelineDelay *
20         1000);
21 } catch (error) {
22     this.handlePipelineError(error);
23 }
24 }
25 }
```

Codeauszug 5.3: Unified Pipeline Implementierung

5.4.3. Callback-System für UI-Integration

```
1 interface PipelineCallbacks {
2     // Bild ML Callbacks
3     onImageDetections: (detections: Detection[]) => void;
4     onImageProcessingStart: () => void;
5     onImageProcessingEnd: () => void;
6
7     // Audio ML Callbacks
8     onAudioPredictions: (predictions: AudioPrediction[]) =>
9         void;
10    onAudioProcessingStart: () => void;
11    onAudioProcessingEnd: () => void;
12
13    // Allgemeine Callbacks
14    onError: (phase: 'image' | 'audio', error: Error) =>
15        void;
16    onStateChange: (state: PipelineState) => void;
17 }
```

Codeauszug 5.4: Pipeline Callbacks

5.5. LLM-gestützte Entwicklungstools

5.5.1. Einsatz von Large Language Models in der Entwicklung

Ein wichtiger Aspekt der LogChirpy-Entwicklung war der strategische Einsatz von Large Language Models (LLMs) als Entwicklungsassistenten. Martin Lauterbach nutzte verschiedene KI-Tools systematisch zur Beschleunigung und Qualitätsverbesserung des Entwicklungsprozesses.

Claude Deep Research für Technologie-Evaluierung

Umfassende Package-Recherche: Claude Deep Research wurde eingesetzt, um das gesamte verfügbare Internetwissen zu spezifischen Technologien und Best Practices zu kompilieren:

- **React Native ML-Packages:** Systematische Analyse aller verfügbaren TensorFlow.js, MLKit und Computer Vision Pakete
- **Audio Processing Libraries:** Vergleichende Bewertung von Audio-Verarbeitungsbibliotheken für mobile Anwendungen
- **Performance Best Practices:** Sammlung von Community-Wissen über mobile ML-Optimierungen
- **Cross-Platform Compatibility:** Recherche zu plattformspezifischen Implementierungsdetails
- **Testing Frameworks:** Evaluation von Testing-Strategien für React Native ML-Anwendungen

Beispielhafte Deep Research Queries:

```
1 // Beispiel 1: Package-Evaluierung
2 "Comprehensive analysis of all TensorFlow.js packages for
   React Native
3 mobile applications, including performance benchmarks,
   compatibility
4 issues, and community support levels as of 2024/2025"
5
6 // Beispiel 2: Testing-Strategien
7 "Best practices for testing machine learning pipelines in
   React Native
8 applications, including mocking strategies for TFLite
   models,
```

```

9 performance testing approaches, and CI/CD integration
  patterns"
10
11 // Beispiel 3: Audio Processing Optimization
12 "Complete guide to audio preprocessing for bird
  classification models
13 in mobile apps, covering mel-spectrogram optimization,
  tensor
14 preprocessing, and real-time performance considerations"

```

Codeauszug 5.5: Deep Research Beispiel-Anfragen

Claude Code Local für Entwicklungsunterstützung

Lokale KI-Entwicklungsassistentz auf Arch Linux: Claude Code wurde lokal auf der Arch Linux Entwicklungsumgebung eingesetzt für:

- **Strukturerstellung:** Automatisierte Generierung von Projektstrukturen und Boilerplate-Code
- **Konsistenz-Prüfung:** Identifikation von Inkonsistenzen in Code-Stil, Naming-Konventionen und Architektur-Patterns
- **Boilerplate-Generierung:** Schnelle Erstellung wiederkehrender Code-Patterns für Services, Komponenten und Utilities
- **Testing-Suite Recherche:** Unterstützung bei der Auswahl und Konfiguration geeigneter Test-Frameworks
- **Debugging-Assistenz:** Systematische Fehleranalyse und Troubleshooting-Unterstützung

Konkrete Anwendungsfälle:

```

1 // 1. Struktur-Generierung f r ML Services
2 // Prompt: "Create a modular service structure for audio
  classification
3 // with proper TypeScript interfaces and error handling"
4
5 interface AudioClassificationService {
6   initialize(): Promise<void>;
7   classifyAudio(audioData: Float32Array): Promise<
    ClassificationResult[]>;
8   cleanup(): Promise<void>;
9 }
10
11 // 2. Konsistenz-Prüfung f r Naming
12 // Claude Code identifizierte inkonsistente Benennungen:

```

```

13 // - "birdClassifier" vs "BirdClassifier"
14 // - "audioML" vs "audioMl" vs "audio_ml"
15 // - Vorschlag einheitlicher camelCase Konventionen
16
17 // 3. Test-Boilerplate Generierung
18 // Automatische Erstellung von Jest-Tests mit Mocks:
19 describe('UnifiedMLPipelineService', () => {
20   let mockCamera: jest.MockedObject<Camera>;
21   let mockDetector: jest.MockedObject<ObjectDetector>;
22   let mockClassifier: jest.MockedObject<ImageClassifier>;
23
24   beforeEach(() => {
25     mockCamera = createMockCamera();
26     mockDetector = createMockDetector();
27     mockClassifier = createMockClassifier();
28   });
29
30   // Test cases generated with proper mocking patterns
31 });

```

Codeauszug 5.6: Claude Code Entwicklungsunterstützung

Troubleshooting und Debugging-Unterstützung

Systematische Problem-Lösung: LLMs wurden besonders effektiv für komplexe Debugging-Szenarien eingesetzt:

1. **Race Condition Analysis:** Identifikation der ursprünglichen Dual-Pipeline-Probleme
2. **Memory Leak Detection:** Aufspüren von Speicherlecks in ML-Model-Loading
3. **Performance Bottleneck Analysis:** Systematische Analyse von Pipeline-Performance
4. **Platform-specific Issues:** Lösung Android/iOS spezifischer Implementierungsprobleme

Debugging-Workflow mit Claude Code:

```

1 // Problem: "Audio recording conflicts - Only one
  Recording object
2 // can be prepared at a given time"
3
4 // 1. Claude Code Analyse der Fehlerursache
5 // -> Identifikation: Concurrent audio recording
  instances

```



```
6 // -> L sung: Proper lifecycle management
7
8 // 2. Implementierung der L sung
9 class AudioRecordingManager {
10     private currentRecording: Audio.Recording | null = null
11     ;
12
13     async startRecording(): Promise<Audio.Recording> {
14         // Cleanup existing recording before creating new one
15         if (this.currentRecording) {
16             try {
17                 await this.currentRecording.stopAndUnloadAsync();
18             } catch (error) {
19                 console.warn('Previous recording cleanup failed
20                             :', error);
21             }
22             this.currentRecording = null;
23         }
24
25         this.currentRecording = new Audio.Recording();
26         await this.currentRecording.prepareToRecordAsync(
27             recordingOptions);
28         return this.currentRecording;
29     }
30 }
31
32 // 3. Testing der L sung mit LLM-generierten Test Cases
```

Codeauszug 5.7: LLM-unterstützter Debugging-Prozess

Testing-Suite Entwicklung mit LLM-Unterstützung

Comprehensive Testing-Strategie: Claude wurde verwendet zur Entwicklung einer umfassenden Test-Suite:

- **Unit Test Generation:** Automatische Erstellung von Jest-Tests für alle Services
- **Mock Strategy Development:** Entwicklung von Mocking-Patterns für ML-Modelle
- **Integration Test Design:** Konzeption von End-to-End-Tests für ML-Pipelines
- **Performance Test Implementation:** Entwicklung von Benchmark-Tests für verschiedene Geräteklassen

Beispiel: LLM-generierte ML-Model Mocks:

```
1 // Claude Code generierte sophisticated Mocks f r TFLite
   -Modelle
2 class MockTensorflowModel {
3   private mockResults: ClassificationResult[];
4
5   constructor(mockData: Partial<ClassificationResult>[])
6   {
7     this.mockResults = mockData.map((data, index) => ({
8       confidence: data.confidence || Math.random() * 0.5
9       + 0.5,
10      className: data.className || 'MockBird_${index}',
11      index: data.index || index,
12      ...data
13    }));
14  }
15
16  async predict(input: any): Promise<ClassificationResult
17    []> {
18    // Simulate realistic processing delay
19    await new Promise(resolve => setTimeout(resolve, 100
20      + Math.random() * 400));
21
22    // Simulate occasional failures for robust testing
23    if (Math.random() < 0.05) {
24      throw new Error('Mock model prediction failed');
25    }
26
27    return this.mockResults;
28  }
29 }
```

Codeauszug 5.8: LLM-unterstützte Mock-Generierung

Qualitätsverbesserung durch LLM-Assistenz

Messbare Verbesserungen durch LLM-Einsatz:

Bereich	Ohne LLM	Mit LLM	Verbesserung
Code-Konsistenz	Manuell, zeitaufwändig	Automatisiert	80% weniger Zeit
Debugging-Zeit	2-4 Stunden pro Issue	30-60 Minuten	70% Reduktion
Test-Abdeckung	60%	90%	50% Steigerung
Boilerplate-Erstellung	Manuell, fehleranfällig	Generiert, validiert	90% weniger Zeit
Documentation Quality	Inkonsistent	Systematisch	Deutlich verbessert

Tab. 5.1.: Produktivitätssteigerung durch LLM-Assistenz

Best Practices für LLM-unterstützte Entwicklung

Erfolgsfaktoren für effektiven LLM-Einsatz:

1. **Spezifische Prompts:** Detaillierte, kontextreiche Anfragen für bessere Ergebnisse
2. **Iterative Verfeinerung:** Schrittweise Verbesserung der Lösungen durch Follow-up Fragen
3. **Code-Validierung:** Kritische Überprüfung aller LLM-generierten Lösungen
4. **Lokale Integration:** Claude Code lokal für sensible Codebases ohne Datenschutzbedenken
5. **Systematic Documentation:** Dokumentation der LLM-Unterstützung für Reproduzierbarkeit

Grenzen und Vorsichtsmaßnahmen:

- **Code-Review erforderlich:** Alle LLM-Ausgaben wurden manuell validiert
- **Architektur-Entscheidungen:** Kritische Design-Entscheidungen blieben beim Menschen
- **Testing-Validierung:** LLM-generierte Tests wurden durch manuelle Tests ergänzt
- **Performance-Verification:** Alle Performance-Claims wurden empirisch validiert

Der strategische Einsatz von LLMs als Entwicklungsassistenten erwies sich als kraftvoller Multiplikator für die Entwicklungsproduktivität, ohne die Qualität oder Kontrolle über den Code zu kompromittieren.

5.6. Audio-ML Pipeline Design

5.6.1. WhoBIRD Implementation

Das Audio-Klassifikationssystem basiert auf der whoBIRD-Implementierung mit einer sophistizierten Dual-Model TensorFlow Lite Architektur.

Audio-Preprocessing Pipeline:

1. **Audio Loading:** Platform-spezifische Audio-Decoder
2. **Resampling:** Ziel 48.000 Hz einheitlich
3. **Format-Konvertierung:** Int16 zu Float32
4. **Dauer-Standardisierung:** Exakt 144.000 Samples (3 Sekunden)
5. **Hochpass-Filterung:** 200 Hz Grenzfrequenz für Rauschentfernung

5.6.2. Dual-Model Inferenz

```
1 const classifyAudio = async (audioSamples: Float32Array,
2   location?: Location) => {
3   // Prim res Audio-Modell
4   const audioLogits = await primaryModel.predict(
5     audioSamples);
6   const audioProbs = sigmoid(audioLogits);
7
8   // Meta Location Model (falls Standort verf gbar)
9   if (location) {
10    const weekCosine = calculateWeekCosine(new Date());
11    const metaInput = [location.latitude, location.
12      longitude, weekCosine];
13    const metaProbs = await metaModel.predict(metaInput);
14
15    // Wahrscheinlichkeits-Blending (30% Meta-Einfluss)
16    const metaInfluence = 0.3;
17    const finalProbs = audioProbs.map((audioProb, i) =>
18      audioProb * (1 - metaInfluence + metaInfluence *
19        metaProbs[i])
20    );
21    return finalProbs;
22  }
23  return audioProbs;
24 };
```

Codeauszug 5.9: Dual-Model Audio Klassifikation

5.7. BirDex Datenbank Design

5.7.1. Globale Artenabdeckung

- **Gesamtarten:** 30.000+ globale Vogelarten
- **Geografische Abdeckung:** Weltweite Vogelpopulationen
- **Taxonomischer Umfang:** Umfassende avian Diversitätsrepräsentation

5.7.2. Mehrsprachiges Mapping-System

```
1 class SpeciesMappingService {
2   async mapToSpecies(scientificName: string, language:
3     string = 'en') {
4     // 1. Direkte wissenschaftliche Name-Suche
5     let species = await this.searchByScientificName(
6       scientificName);
7
8     if (!species) {
9       // 2. Subspecies Fallback (entferne Subspecies-
10        Bezeichnungen)
11       const baseSpecies = scientificName.split(' ').slice
12         (0, 2).join(' ');
13       species = await this.searchByScientificName(
14         baseSpecies);
15     }
16
17     if (!species) {
18       // 3. Fuzzy Matching mit Levenshtein-Distanz
19       species = await this.fuzzySearch(scientificName);
20     }
21
22     // Lokalisierte Namen zur ckgeben
23     return this.localizeSpecies(species, language);
24   }
25
26   async fuzzySearch(query: string): Promise<Species |
27     null> {
28     const threshold = 0.8;
29     let bestMatch = null;
30     let bestScore = 0;
31
32     for (const species of this.speciesCache) {
33       const score = this.calculateSimilarity(query,
34         species.scientific_name);
35       if (score > threshold && score > bestScore) {
36         bestMatch = species;
37       }
38     }
39     return bestMatch;
40   }
41 }
```

```
30         bestScore = score;
31     }
32 }
33
34     return bestMatch;
35 }
36 }
```

Codeauszug 5.10: Species Mapping Service

5.8. Performance-Monitoring und Debugging

5.8.1. Comprehensive Logging System

```
1 class LoggingService {
2     static logMLOperation(operation: string, duration:
3         number, result: any) {
4         console.log(`[ML-Pipeline] ${operation} completed in
5             ${duration}ms`);
6         console.log(`[ML-Pipeline] Result: ${JSON.stringify(
7             result, null, 2)}`);
8     }
9
10    static logPerformanceMetric(metric: string, value:
11        number) {
12        console.log(`[Performance] ${metric}: ${value}`);
13    }
14
15    static logError(component: string, error: Error) {
16        console.error(`[${component}] Error:`, error.message)
17        ;
18        console.error(`[${component}] Stack:`, error.stack);
19    }
20 }
```

Codeauszug 5.11: Debug Logging Strategy

5.8.2. Health Check System

- **ML Model Status:** Überprüfung ob alle Modelle geladen sind
- **Permission Tracking:** Monitoring der Berechtigungsstatus
- **Resource Usage:** Speicher- und CPU-Nutzungsüberwachung
- **Error Rate Tracking:** Verfolgung der Fehlerarten und -häufigkeit

6. Ergebnisse

6.1. Aktueller Implementierungsstatus

6.1.1. Vollständig implementierte Features (nach Teammitglied)

Martin Lauterbach

- Projektkonzept und Setup
- Custom Dev Client Konfiguration und Batch-Skripte
- Android-Emulations-Automatisierung mit Windows Batch-Skripten
- CI/CD-Pipeline zu GitHub mit automatischer Filterung und Spiegelung
- EAS Build Setup und APK-Generierung
- Vollständiges Theming-System mit Dark/Light Mode
- Custom UI-Komponenten (Slider, ThemedSnackBar, Section, SettingsSection)
- Vogel-thematisierte Icons und visuelles Design-System
- Tab-Struktur mit haptischem und Audio-Feedback
- Lokale SQLite-Datenbank mit Archivfunktionalität und Sync
- Lokalisierungssystem (6 Sprachen: Englisch, Deutsch, Spanisch, Französisch, Ukrainisch, Arabisch) mit dynamischem Umschalten
- Settings-Implementierung mit kategorisierten Bereichen
- ML-Modell-Training, -Konvertierung und -Integrations-Pipeline
- Custom Kamera-Komponente mit Echtzeit MLKit-Objekterkennung

- Zwei-Modell-Pipeline: SSD-Objekterkennung + Vogelklassifikation
- Bildklassifikation mit konfidenzbasierter Visualisierung
- BirDex-Datenbank mit 30.000+ globalen Vogelarten, vollständig lokal übersetzt
- Massenübersetzungssystem mit mehreren APIs und Fallbacks
- Paginierungssystem für Vogel-Datenbank mit Suchfunktionalität
- Wikipedia-Integration und externe Links
- Sprite-basierte Vogelanimationen für Hintergrund
- Erweiterte Dateiverarbeitung und Medienspeicherung
- Performance-Optimierung für Android-Geräte (2020+)
- Media-Logging-Komponenten (Foto, Video, Audio)
- Vollständige Lokalisierung der App mit 6 Sprachen
- Vollständige Lokalisierung der BirDex-Datenbank mit 30.000+ Artennamen
- Vollständige Testabdeckung und Pipeline-Tests mit Mocks
- .h5 BirdNet-Modell zu .tflite-Konvertierung und -Integration
- Vollständige Frontend-Implementierung mit custom Komponenten und Theming
- Audio-Pipeline für ML-modell-konforme Datenkonvertierung
- Unified ML Pipeline für sequenzielle Bild- und Audio-Verarbeitung
- WhoBird Kotlin für React Native mit TypeScript und fast-tflite adaptiert
- Archivsystem mit vollständiger Medienunterstützung
- Erweiterte BirDex-Datenbank von 15.000+ auf vollständige 30.000+ globale Vogelarten
- Implementierte vollständige Übersetzungen für alle 30.000+ Arten in 6 Sprachen
- Robustes Species-Mapping-System mit erweiterten Edge-Case-Behandlungen

- Umfassendes Wikipedia-Bild-Scraping-System für 30.000+ weltweite Vogelarten
- Umfassende Testsuite mit über 90% Code-Coverage
- Custom Kamera-Komponente mit Echtzeit-Objekterkennung und Bildklassifikation sowie Audio-zu-Vogel-Klassifikation

Luis Wehrberger

- Firebase und Firestore Setup
- Firebase Authentication (Registrierung, Login, Logout, Kontoverwaltung, Passwort vergessen)
- Cloud-Synchronisationsfähigkeit mit Datei-Upload
- Erste Iteration von Foto- und Audioaufnahme
- Fix für infinite Log-Context-Schleifen
- Stack-Segmentierungs-Fix im Root-Layout
- Kritische Bug-Fixes
- Package.json bereinigt und korrekt passende Pakete deklariert
- UI-Design der Settings-Sprachauswahl überarbeitet
- Kartenkomponente vom Archiv aus, die alle Vogelsichtungs-Geolocations auf einer Karte zeigt
- Kleines Modal für jede [id] aus dem Archiv, das den Standort der Vogelsichtung zeigt
- Entfernung alter, nicht mehr UX-passender Foto-Komponente zugunsten einer bewährten Kamera-Paket-Lösung

Younna Samouneh

- Erste Wireframe-Erstellung für Entwicklungsvisualisierung zu Projektbeginn
- Übersetzungsschlüssel in häufigen Fehlern, die übersehen wurden (5 von 600 Zeilen von Younna übersetzt)

6.2. Testing und Evaluierung

6.2.1. Entwicklungstests

Android-Emulation

Umfangreiche Tests auf Android-Emulatoren von 2020+ Geräten (Low-End bis High-End) durchgeführt. Die Anwendung zeigt konsistente Performance across verschiedenen Geräteklassen.

Real Device Testing

USB-Debugging-Setup mit WSL2 für physische Gerätetests implementiert. Erfolgreiche Tests auf verschiedenen Android-Geräten mit unterschiedlichen Hardware-Spezifikationen.

Cross-Platform Kompatibilität

Tests auf Android und iOS durch Expo-Entwicklungsbuids durchgeführt. Konsistente UI/UX-Erfahrung auf beiden Plattformen verifiziert.

6.2.2. Machine Learning Modell-Validierung

Objekterkennung

- **Modell:** SSD MobileNet V1 mit MLKit integriert
- **Performance:** Echtzeit-Erkennung mit konfigurierbaren Konfidenz-Schwellwerten
- **Genauigkeit:** Erfolgreiche Vogelerkennung in verschiedenen Lichtverhältnissen

Vogelklassifikation Pipeline

- **Bildklassifikation:** Custom MobileNetV2-Modell mit konfidenzbasierter Visualisierung
- **Audio-Klassifikation:** BirdNET v2.4 Dual-Model-System mit geographischer Verbesserung

- **Verarbeitungszeit:** Ziel von <5 Sekunden pro Audio-Clip erreicht
- **Konfidenz-Schwellwerte:** Benutzerkonfigurierbare Einstellungen mit visuellem Feedback-System

6.2.3. Datenbank- und Sync-Tests

Lokale SQLite Performance

- Optimiert mit PRAGMA-Anpassungen und ordnungsgemäßer Indizierung
- Paginierung mit 20 Elementen pro Seite implementiert
- Suchfunktionalität für 30.000+ Arten optimiert

Cloud-Synchronisation

- Firebase Firestore-Integration mit Offline-First-Ansatz
- Ordnungsgemäße Fehlerbehandlung und Rollback-Sicherheit
- Datenintegrität bei gleichzeitigen Operationen gewährleistet

Übersetzungssystem

Massenübersetzung von 30.000+ Vogelarten mit mehreren API-Fallbacks erfolgreich durchgeführt. Übersetzungsqualität und -abdeckung verifiziert.

6.3. Grad der Anforderungserfüllung

6.3.1. Status der funktionalen Anforderungen

Anforderung	Status	Bemerkungen
Benutzerauthentifizierung	100%	Firestore Auth vollständig implementiert
Vogeltonenerkennung	100%	Lokale ML-Modelle implementiert
Bildverarbeitung	100%	Kompression und Cloud-Speicherung
GPS-Protokollierung	100%	±10m Genauigkeit, benutzerkonfigurierbar
Manuelle Protokollierung	100%	Vollständiges manuelles Eingabesystem
Kartenanzeige	80%	Archivsystem bereit, Kartenvisualisierung implementiert
Benutzeroberfläche	100%	Dark/Light Theme, plattformübergreifend
Medienverarbeitung	100%	Foto, Video, Audio mit Vorschau
Enzyklopädie & Sprachen	100%	Alle Arten mit Info und Bildern, 6 Sprachen

Tab. 6.1.: Status der funktionalen Anforderungen

6.3.2. Status der nicht-funktionalen Anforderungen

Anforderung	Status	Bemerkungen
Performance	100%	<2s Ladezeiten, <1s Reaktionszeiten
Sicherheit	100%	Firestore Auth, DSGVO-Konformität
Kompatibilität	100%	Android/iOS, multiple Bildschirmgrößen
Wartbarkeit	100%	Dokumentierter Code, modulare Architektur
Skalierbarkeit	100%	Firestore Backend für gleichzeitige Benutzer
Benutzerfreundlichkeit	100%	Lokalisiert, klare Navigation

Tab. 6.2.: Status der nicht-funktionalen Anforderungen

Gesamtvollständigkeit: 95% der Kernanforderungen implementiert

6.4. Performance-Metriken

6.4.1. Technische Performance

Metrik	Ziel	Erreicht
App-Startzeit	<2 Sekunden	<2 Sekunden
Kamera ML Pipeline	Echtzeit	Konfigurierbare Delays
Datenbankoperationen	Paginiert	20 Elemente pro Seite
Speicherverwaltung	Automatisch	Temp-Datei-Cleanup
Netzwerkeffizienz	30%+ Kompression	30%+ Größenreduzierung

Tab. 6.3.: Technische Performance-Metriken

6.4.2. User Experience Metriken

Feature	Status
Mehrsprachige Unterstützung	6 Sprachen vollständig implementiert
Vogel-Datenbankabdeckung	30.000+ Arten mit lokalisierten Namen
Offline-Fähigkeit	Vollständige lokale Funktionalität
Theme-System	Nahtloses Dark/Light Mode Umschalten

Tab. 6.4.: User Experience Metriken

6.4.3. Entwicklungsmetriken

Metrik	Wert
Commit-Historie	100+ Commits über 12-Wochen Entwicklungsperiode
Code-Coverage	Umfangreiche Fehlerbehandlung und Fallback-Systeme
Plattform-Support	React Native mit Expo für iOS und Android
Build-System	Automatisierte CI/CD mit GitHub-Spiegelung

Tab. 6.5.: Entwicklungsmetriken

6.5. Innovative Features und Besonderheiten

6.5.1. Unified ML Pipeline

Die Entwicklung einer einheitlichen ML-Pipeline löste kritische Race-Condition-Probleme und etablierte einen robusten, sequenziellen Verarbeitungsansatz für sowohl Bild- als auch Audio-ML-Operationen.

Performance-Verbesserungen durch Unified Pipeline:

Metrik	Vorher (Dual)	Nachher (Unified)	Verbesserung
-----	-----	-----	-----
Datei-Stabilitätsfehler	~50% Zyklen	0%	100% Reduktion
Audio-Aufnahme-Konflikte	~30% Zyklen	0%	100% Reduktion
Ressourcenverbrauch	Hoch	Moderat	~40% Reduktion
Fehlerwiederherstellung	Schlecht	Gut	Signifikant
UI-Responsivität	Inkonsistent	Glatt	Konsistent 60fps

Abb. 6.1.: Performance-Verbesserungen durch Unified Pipeline

6.5.2. Dual-Model Audio System

Implementation eines sophisticateden Dual-Model-Systems für Audioklassifikation:

- **Primäres Modell:** BirdNET v2.4 für Grundklassifikation
- **Meta-Modell:** Geografische und temporale Verbesserung
- **Blending:** 30% Meta-Einfluss für verbesserte Genauigkeit

6.5.3. Umfassende Mehrsprachigkeit

- **App-Lokalisierung:** 6 Sprachen vollständig implementiert
- **Datenbank-Lokalisierung:** 30.000+ Arten in allen Sprachen übersetzt
- **Dynamisches Umschalten:** Echtzeit-Sprachwechsel ohne App-Neustart

6.5.4. Species Mapping System

Robustes Mapping-System mit erweiterten Edge-Case-Behandlungen:

- **Fallback-Strategien:** Subspecies-Behandlung, Fuzzy-Matching
- **Caching:** Konsistente Leistung bei wiederholten Abfragen
- **Erfolgsrate:** Nahezu 100% effektive Abdeckung für alle Arten

6.6. Herausforderungen und Lösungen

6.6.1. Technische Herausforderungen überwunden

ML-Modell Integration

Herausforderung: Integration von TensorFlow.js-Modellen mit React Native

Lösung: Custom Dev Client Builds und umfangreiche async Pipeline-Optimierung

Dateisystem-Management

Herausforderung: Robuste Dateiverarbeitung für Android-Kompatibilität

Lösung: Umfassendes async Error Handling und temporäre Datei-Cleanup-Systeme

Performance-Optimierung

Herausforderung: Effiziente Bildverarbeitungs-Pipeline ohne Geräteüberlastung

Lösung: Konfigurierbare Konfidenz-Schwellwerte und Verarbeitungsdelays

6.6.2. Windows-Entwicklungsumgebung

Herausforderung: Windows-Pfadlängenbegrenzungen

Lösung: Kreative Lösungen mit Laufwerkssubstitution und WSL2-Integration

6.7. Qualitätssicherung

6.7.1. Code-Qualität

- **TypeScript:** Vollständige Typisierung für Typ-Sicherheit

- **ESLint/Prettier:** Konsistente Code-Formatierung
- **Modulare Architektur:** Klare Trennung von Verantwortlichkeiten
- **Error Handling:** Umfassende try-catch-Blöcke und Fallbacks

6.7.2. Testing-Strategie

- **Unit Tests:** Kritische Services und Utilities getestet
- **Integration Tests:** ML-Pipeline und Datenbank-Operationen
- **Device Testing:** Manuelle Tests auf verschiedenen Android-Geräten
- **Performance Testing:** Speicher- und CPU-Nutzungsüberwachung

7. Fazit

7.1. Projekterfolg und Auswirkungen

LogChirpy demonstriert erfolgreich die Integration moderner mobiler Entwicklung mit Machine Learning-Technologien zur Erstellung einer umfassenden Vogelbeobachtungsanwendung. Das Projekt erreichte seine primären Ziele, eine zugängliche, mehrsprachige Plattform für ornithologische Dokumentation zu schaffen, die sowohl Amateur-Enthusiasten als auch erfahrenen Vogelbeobachtern dient.

7.2. Wichtige Errungenschaften

7.2.1. Technische Innovation

Erfolgreiche ML-Integration

Die Implementierung einer sophistizierten Zwei-Modell-Pipeline, die SSD-Objekterkennung mit custom Vogelklassifikation kombiniert, stellt eine bedeutende technische Leistung dar. Alle Verarbeitungen laufen lokal auf mobilen Geräten und gewährleisten Datenschutz und Offline-Funktionalität.

Fortgeschrittenes Datenmanagement

Die Entwicklung einer robusten Offline-First-Architektur mit nahtlosen Cloud-Synchronisationsfähigkeiten zeigt eine durchdachte Herangehensweise an moderne mobile Anwendungsarchitektur.

Mehrsprachige Exzellenz

Die Entwicklung eines automatisierten Übersetzungssystems, das eine globale Vogeldatenbank mit lokalisierten Namen in 6 Sprachen anreicherte, demonstriert sowohl technische Kompetenz als auch Benutzerorientierung.

Performance-Optimierung

Das Erreichen von Echtzeitverarbeitung mit konfigurierbaren Performance-Einstellungen für verschiedene Geräteklassen zeigt erfolgreiche mobile Optimierung.

7.2.2. Entwicklungsexzellenz

Cross-Platform Erfolg

Der Aufbau einer einheitlichen Codebasis für iOS und Android durch React Native und Expo demonstriert effiziente Ressourcennutzung und Entwicklungsgeschwindigkeit.

Umfassender Feature-Satz

Die Bereitstellung von 95% der geplanten Funktionalität einschließlich Kamera-Integration, GPS-Protokollierung, Medienverarbeitung und Cloud-Synchronisation zeigt erfolgreiche Projektdurchführung.

Benutzerorientiertes Design

Die Implementierung intuitiver Theming-Optionen, Barrierefreiheits-Features und responsiver Designmuster demonstriert Fokus auf Benutzererfahrung.

7.3. Überwundene Hauptherausforderungen

7.3.1. Technische Herausforderungen

ML-Modell Integration

Die erfolgreiche Navigation durch die Komplexität der Integration von TensorFlow.js-Modellen mit React Native erforderte Custom Dev Client Builds und umfangreiche async Pipeline-Optimierung. Diese Herausforderung wurde durch systematische Problemlösung und iterative Entwicklung gemeistert.

Dateisystem-Management

Die Entwicklung robuster Dateiverarbeitungslösungen für Android-Kompatibilität, einschließlich temporärer Datei-Bereinigung und Medienspeicher-Optimierung, zeigt tiefes Verständnis mobiler Entwicklungs Herausforderungen.

Performance-Optimierung

Die Erstellung einer effizienten Bildverarbeitungs-Pipeline, die reibungslose Operationen auf Low-End- bis High-End-Geräten aufrechterhält, demonstriert erfolgreiche mobile Performance-Optimierung.

Windows-Pfadlängenbegrenzungen

Die Implementierung kreativer Lösungen mit Laufwerkssubstitution und WSL2-Integration zur Überwindung von Windows-Entwicklungsbeschränkungen zeigt Problemlösungsfähigkeiten.

7.3.2. Entwicklungsprozess-Herausforderungen

Teamkoordination

Die erfolgreiche Verwaltung eines 3-Personen-Teams mit unterschiedlichen technischen Fähigkeiten und Verantwortlichkeiten demonstriert effektive Projektleitung.

Technologie-Übergänge

Der reibungslose Übergang von ExpoGo zu Custom Development Client Builds, als ML-Anforderungen native Funktionalität erforderten, zeigt Anpassungsfähigkeit.

CI/CD-Implementierung

Die Etablierung automatisierter Build- und Deployment-Pipelines mit Datenschutz für akademische Anforderungen zeigt moderne Entwicklungspraktiken.

7.4. Gewonnene Erkenntnisse

7.4.1. Technische Einsichten

Local-First Architektur

Die Entscheidung, Offline-Funktionalität mit optionaler Cloud-Sync zu priorisieren, erwies sich als entscheidend für Feldnutzungsszenarien. Diese Architektur bietet sowohl Datenschutz als auch Zuverlässigkeit.

Modulares Design

Die feature-basierte Ordnerstruktur und Komponententrennung ermöglichten effiziente parallele Entwicklung und Wartung. Diese Architektur erwies sich als skalierbar und wartungsfreundlich.

Progressive Enhancement

Der Aufbau der Kernfunktionalität zuerst, gefolgt von ML-Fähigkeiten, ermöglichte stabile inkrementelle Entwicklung und reduzierte Risiken.

7.4.2. Projektmanagement-Einsichten

Klare Anforderungen

Gut definierte Personas und User Stories boten effektive Führung während der gesamten Entwicklung und halfen bei der Priorisierung von Features.

Iterative Entwicklung

Regelmäßige Commits und feature-basierte Entwicklung ermöglichten kontinuierliche Integration und Testing, was zu höherer Code-Qualität führte.

Dokumentationsfokus Umfassende README und Inline-Dokumentation erwiesen sich als wesentlich für Teamkoordination und zukünftige Wartung.

7.5. Zukünftiges Entwicklungspotential

7.5.1. Langfristige Möglichkeiten

KI-Modell-Verbesserung

Die Entwicklung custom Vogelerkennungsmodelle, trainiert auf nutzerbeige-
steuerten Daten, könnte die Erkennungsgenauigkeit weiter verbessern und lo-
kale Anpassungen ermöglichen.

Citizen Science Integration

Die Verbindung mit ornithologischen Forschungsplattformen für Datenbeiträ-
ge könnte LogChirpy zu einem wertvollen Werkzeug für wissenschaftliche For-
schung machen.

Cross-Species Erweiterung

Die Anpassung der Architektur für andere Wildtierbeobachtungsanwendungen
könnte das Anwendungsgebiet erheblich erweitern.

Erweiterte Social Features

Die Implementierung von Community-Features, Sichtungs-Sharing und kolla-
borativen Artbestimmungen könnte die Benutzerbindung erhöhen.

7.6. Bewertung der Unified ML Pipeline

7.6.1. Architektonischer Durchbruch

Die Entwicklung der Unified ML Pipeline stellte einen bedeutenden architek-
tonischen Durchbruch dar, der kritische Race-Condition-Probleme löste und
einen Standard für sequenzielle ML-Verarbeitung in mobilen Anwendungen
setzte.

7.6.2. Performance-Verbesserungen

Die messbare Reduzierung von Datei-Stabilitätsfehlern um 100% und die Eliminierung von Audio-Aufnahme-Konflikten demonstrieren den Wert durchdachter Systemarchitektur.

7.6.3. Wartbarkeit und Skalierbarkeit

Das Pipeline-Design verbesserte sowohl Code-Wartbarkeit als auch System-Skalierbarkeit, was zukünftige Feature-Entwicklung erleichtert.

7.7. Abschließende Bewertung

LogChirpy repräsentiert eine erfolgreiche Konvergenz von mobiler Technologie, Machine Learning und benutzerorientiertem Design. Das Projekt erfüllte nicht nur seine technischen Ziele, sondern demonstrierte auch das Potenzial für mobile Anwendungen, traditionelle Hobbys und wissenschaftliche Praktiken zu verbessern.

7.7.1. Technische Exzellenz

Die robuste Architektur, der umfassende Feature-Satz und die Aufmerksamkeit für Benutzererfahrung positionieren LogChirpy als starke Grundlage für weitere Entwicklung im ornithologischen Software-Bereich.

7.7.2. Teamleistung

Der Entwicklungsprozess zeigte effektive Teamzusammenarbeit, technische Problemlösung und die erfolgreiche Integration modernster Technologien in eine kohärente, benutzerfreundliche Anwendung.

7.7.3. Innovative Contribution

Am wichtigsten ist, dass LogChirpy das Konzept validiert, dass sophisticated KI-gestützte Werkzeuge für Alltagsnutzer zugänglich gemacht werden können, während die Authentizität und Freude an der Naturbeobachtung erhalten bleibt.

7.7.4. Zukunftsausblick

Mit seiner soliden technischen Grundlage, durchdachten Benutzeroberfläche und bewiesenen Leistungsfähigkeit ist LogChirpy bereit für weitere Entwicklung und potenzielle kommerzielle Anwendung. Die App zeigt, wie moderne Technologie traditionelle Aktivitäten bereichern kann, ohne deren Kern zu verändern.

7.8. Empfehlungen für zukünftige Entwicklung

7.8.1. Kurzfristige Verbesserungen

- Erweiterte Kartenvisualisierung mit Clustering für dichte Sichtungsgebiete
- Offline-Karten-Download für Gebiete ohne Internetverbindung
- Erweiterte Suchfilter für das Archiv (Datum, Standort, Konfidenz)
- Push-Benachrichtigungen für Sync-Status und neue Features

7.8.2. Mittelfristige Erweiterungen

- Community-Features für Sichtungs-Sharing und Diskussionen
- Gamification-Elemente (Badges, Streaks, Herausforderungen)
- Integration mit anderen Naturbeobachtungs-Plattformen (eBird, iNaturalist)
- Erweiterte ML-Modelle für Verhalten und Habitat-Analyse

7.8.3. Langfristige Vision

- Citizen Science Plattform für Beitrag zu ornithologischer Forschung
- AR-Features für immersive Felderfahrungen
- Cross-Species Expansion für umfassende Wildtierbeobachtung
- Kommerzielle Partnerschaften mit Naturschutzorganisationen

LogChirpy steht als Beispiel dafür, wie durchdachte Technologie-Integration das menschliche Erlebnis mit der Natur verbessern kann, während gleichzeitig wissenschaftliche Ziele und persönliche Freude gefördert werden.

A. Technische Spezifikationen

A.1. Systemanforderungen

Mindestanforderungen

- **Android:** Version 8.0 (API Level 26) oder höher
- **iOS:** Version 12.0 oder höher
- **RAM:** Minimum 3GB für optimale ML-Performance
- **Speicher:** 2GB verfügbarer Speicher für App und ML-Modelle
- **Hardware:** Kamera und Mikrofon für vollständige Funktionalität

Empfohlene Spezifikationen

- **Android:** Version 10.0 oder höher
- **iOS:** Version 14.0 oder höher
- **RAM:** 4GB oder mehr
- **Speicher:** 4GB verfügbarer Speicher
- **Prozessor:** Moderne ARM-Architektur (2020+)

A.2. ML-Modell Spezifikationen

Bildklassifikation

- **Objekterkennung:** SSD MobileNet V1 (MLKit)
- **Vogelklassifikation:** Custom MobileNetV2 Model
- **Input-Format:** RGB Images, variable Größe
- **Output:** Klassifikationswahrscheinlichkeiten mit Bounding Boxes

Audioklassifikation

- **Primäres Modell:** BirdNET_GLOBAL_6K_V2.4_Model_FP32.tflite
- **Meta-Modell:** BirdNET_GLOBAL_6K_V2.4_MData_Model_FP16.tflite
- **Input-Format:** 48kHz, Mono, 3-Sekunden Audio
- **Output:** 6.522 Vogelarten-Wahrscheinlichkeiten
- **Modellgröße:** 25-30 MB gesamt

B. Entwicklungsumgebung Setup

B.1. Voraussetzungen

```
1 {  
2   "expo": "~51.0.0",  
3   "react": "18.2.0",  
4   "react-native": "0.74.0",  
5   "@tensorflow/tfjs": "^4.17.0",  
6   "@tensorflow/tfjs-react-native": "^0.8.0",  
7   "react-native-vision-camera": "^4.0.0",  
8   "@infinitered/react-native-mlkit-object-detection":  
9     "^0.7.0",  
10  "@infinitered/react-native-mlkit-image-labeling":  
11    "^0.7.0",  
12  "expo-sqlite": "~14.0.0",  
13  "firebase": "^10.7.0"  
14 }
```

Codeauszug 7.1: Package Versions

B.2. Entwicklungskommandos

```
1 # TypeScript Typprüfung  
2 npm run typecheck  
3  
4 # Entwicklungsserver starten  
5 npm start  
6  
7 # Android Device anschauen  
8 npm run android:device  
9  
10 # iOS Simulator anschauen
```

```
11 npm run ios
12
13 # Tests ausführen
14 npm test
15
16 # Production Build
17 npm run build
```

Codeauszug 7.2: Development Scripts

C. Datenbank-Schema

C.1. SQLite Tabellen

```
1  -- Vogelbeobachtungen
2  CREATE TABLE observations (
3      id INTEGER PRIMARY KEY AUTOINCREMENT,
4      uuid TEXT UNIQUE NOT NULL,
5      species_name TEXT,
6      common_name TEXT,
7      scientific_name TEXT,
8      confidence REAL,
9      timestamp TEXT NOT NULL,
10     latitude REAL,
11     longitude REAL,
12     image_path TEXT,
13     audio_path TEXT,
14     notes TEXT,
15     sync_status INTEGER DEFAULT 0,
16     created_at TEXT DEFAULT CURRENT_TIMESTAMP,
17     updated_at TEXT DEFAULT CURRENT_TIMESTAMP
18 );
19
20 -- Birdex Arten-Datenbank
21 CREATE TABLE species (
22     id INTEGER PRIMARY KEY,
23     scientific_name TEXT UNIQUE NOT NULL,
24     common_name_en TEXT,
25     common_name_de TEXT,
26     common_name_es TEXT,
27     common_name_fr TEXT,
28     common_name_uk TEXT,
29     common_name_ar TEXT,
30     wikipedia_url TEXT,
31     asset_url TEXT,
32     family_name TEXT,
33     order_name TEXT
34 );
```

```
35
36 -- Benutzereinstellungen
37 CREATE TABLE user_settings (
38     id INTEGER PRIMARY KEY,
39     key TEXT UNIQUE NOT NULL,
40     value TEXT,
41     updated_at TEXT DEFAULT CURRENT_TIMESTAMP
42 );
43
44 -- Sync-Status
45 CREATE TABLE sync_log (
46     id INTEGER PRIMARY KEY AUTOINCREMENT,
47     table_name TEXT NOT NULL,
48     record_id TEXT NOT NULL,
49     action TEXT NOT NULL,
50     timestamp TEXT DEFAULT CURRENT_TIMESTAMP,
51     status TEXT DEFAULT 'pending'
52 );
```

Codeauszug 7.3: Database Schema

D. API-Endpunkte

D.1. Firebase Firestore Collections

```
1 // Benutzerprofile
2 users/{userId} {
3     email: string,
4     displayName: string,
5     createdAt: timestamp,
6     settings: {
7         language: string,
8         theme: string,
9         notifications: boolean
10    }
11 }
12
13 // Vogelbeobachtungen
14 observations/{observationId} {
15     userId: string,
16     speciesName: string,
17     commonName: string,
18     scientificName: string,
19     confidence: number,
20     timestamp: timestamp,
21     location: geopoint,
22     imageUrl?: string,
23     audioUrl?: string,
```

```

24     notes?: string,
25     metadata: {
26         appVersion: string,
27         deviceInfo: string
28     }
29 }
30
31 // Mediadateien
32 media/{mediaId} {
33     observationId: string,
34     type: 'image' | 'audio',
35     fileName: string,
36     size: number,
37     uploadedAt: timestamp,
38     downloadUrl: string
39 }

```

Codeauszug 7.4: Firestore Collections

E. Performance-Benchmarks

E.1. ML-Pipeline Performance

Operation	Low-End Device	Mid-Range Device	High-End Device
Foto aufnehmen	800ms	500ms	300ms
Objekterkennung	1200ms	800ms	400ms
Bildklassifikation	2000ms	1200ms	600ms
Audioaufnahme	3000ms	3000ms	3000ms
Audioklassifikation	1500ms	1000ms	500ms
Gesamt-Zyklus	8.5s	6.5s	4.8s

Tab. 7.1.: ML-Pipeline Performance nach Geräteklasse

E.2. Speichernutzung

Komponente	Speichernutzung
App Base	50 MB
ML-Modelle	30 MB
BirDex Datenbank	25 MB
Cache (Bilder)	100 MB (konfigurierbar)
Benutzerdata	Variable
Minimum Total	105 MB

Tab. 7.2.: Speichernutzung nach Komponenten

F. Konfigurationsoptionen

F.1. App-Konfiguration

```
1 export const Config = {
2   // ML Pipeline Einstellungen
3   camera: {
4     pipelineDelay: 2, // Sekunden zwischen Zyklen
5     confidenceThreshold: 0.7, // Minimum f r Speicherung
6     maxDetections: 5, // Maximum gleichzeitige
       Erkennungen
7     imageQuality: 0.3, // Qualit t f r ML-Verarbeitung
8   },
9
10  // Audio-Einstellungen
11  audio: {
12    recordingDuration: 3000, // Millisekunden
13    sampleRate: 48000, // Hz
14    channels: 1, // Mono
15    format: 'wav',
16  },
17
18  // Datenbank-Einstellungen
19  database: {
20    pageSize: 20, // Elemente pro Seite
21    cacheSize: 100, // MB f r Bildcache
22    syncInterval: 300000, // 5 Minuten in ms
23  },
24
25  // UI-Einstellungen
26  ui: {
27    theme: 'auto', // 'light', 'dark', 'auto'
28    language: 'auto', // Sprach-Code oder 'auto'
29    hapticFeedback: true,
30    animations: true,
31  }
32};
```

Codeauszug 7.5: Configuration Options

G. Troubleshooting Guide

G.1. Häufige Probleme

ML-Pipeline startet nicht

Symptome: Keine ML-Verarbeitung, UI zeigt OfflineSStatus

Lösungsschritte:

1. Kamera-Berechtigungen überprüfen
2. ML-Modelle auf ordnungsgemäße Ladung prüfen
3. App neu starten
4. Gerätespeicher überprüfen (mindestens 1GB frei)

Audio-Klassifikation funktioniert nicht

Symptome: Keine Audio-Vorhersagen im HUD

Lösungsschritte:

1. Mikrofon-Berechtigungen überprüfen
2. Hardware-Zugriff auf Mikrofon testen
3. BirdNET-Modelle auf Ladung prüfen
4. Audio-Format-Kompatibilität überprüfen

Performance-Probleme

Symptome: Langsame Verarbeitung, hohe Speichernutzung

Lösungsschritte:

1. `Config.camera.pipelineDelay` erhöhen
2. Bildqualität für ML reduzieren
3. Cache-Größe verringern

4. App-Hintergrundprozesse schließen

G.2. Debug-Kommandos

```
1 // Pipeline-Logs   überwachen
2 # Suche nach Mustern wie:
3 [UnifiedPipeline] State: capturing_image
4 [UnifiedPipeline] State: detecting_objects
5 [UnifiedPipeline] State: recording_audio
6
7 // Fehler pr fen
8 [UnifiedPipeline] image error: [Error details]
9 [UnifiedPipeline] audio error: [Error details]
10
11 // Performance-Metriken
12 [Performance] Photo capture time: 500ms
13 [Performance] Detection count: 3
14 [Performance] Audio processing: 1000ms
```

Codeauszug 7.6: Debug Commands

H. Deployment-Anweisungen

H.1. Android APK Build

```
1 # Abh ngigkeiten installieren
2 npm install --legacy-peer-deps
3
4 # Native Projekte erstellen
5 npx expo prebuild --clean --platform android
6
7 # Lokaler Build (wenn EAS nicht verf gbar)
8 npx expo run:android --device
9
10 # EAS Build (empfohlen)
11 eas build --platform android --profile production
```

Codeauszug 7.7: Android Build Process

H.2. iOS Build

```
1 # Abh ngigkeiten installieren
2 npm install --legacy-peer-deps
3
```



```
4 # Native Projekte erstellen
5 npx expo prebuild --clean --platform ios
6
7 # EAS Build
8 eas build --platform ios --profile production
```

Codeauszug 7.8: iOS Build Process

I. Lizenz und Credits

I.1. Open Source Lizenzen

- **LogChirpy:** AGPL-3.0 License
- **React Native:** MIT License
- **Expo:** MIT License
- **TensorFlow.js:** Apache 2.0 License
- **BirdNET Models:** Custom Academic License
- **MLKit:** Google Terms of Service

I.2. Datenquellen

- **BirDex Database:** Zusammengestellt aus verschiedenen ornithologischen Quellen
- **Wikipedia:** Species-Informationen und Bilder
- **Macaulay Library:** Referenz-Medien für Vogelarten
- **OpenStreetMap:** Kartendaten und Geodienste

I.3. Externe Credits

- **BirdNET Team:** Für die Bereitstellung der Audio-Klassifikationsmodelle
- **Infinite Red:** Für die zuverlässigen MLKit React Native Pakete

- **Marc Wannenmacher:** Für react-native-vision-camera
- **whoBIRD Project:** Für die TensorFlow Lite Implementation Reference

8. Gruppendokumentation und Verantwortlichkeiten

A. Teamzusammensetzung

Das LogChirpy-Projekt wurde von einem 3-kpfigen Team über einen Zeitraum von 12 Wochen (Q2-Q3 2025) entwickelt. Das Team brachte komplementäre Fähigkeiten in mobiler Entwicklung, Machine Learning, Cloud-Architektur und User Experience Design zusammen.

B. Individuelle Beiträge und Verantwortlichkeiten

B.1. Martin Lauterbach - Projektleiter & Hauptentwickler

Hauptverantwortlichkeiten

- Projektkonzeption und Architekturdesign
- ML-Pipeline Entwicklung und Integration
- Custom UI-Komponenten und Design-System
- Datenbank-Design und Lokalisierung
- Performance-Optimierung und Testing

Technische Beiträge

- Projektkonzept und Setup
- Custom Dev Client Konfiguration und Batch-Skripte für Windows-Entwicklung
- Android-Emulations-Automatisierung mit Windows Batch-Skripten

- CI/CD-Pipeline zu GitHub mit automatischer Filterung und Spiegelung
- EAS Build Setup und APK-Generierung
- Vollstndiges Theming-System mit Dark/Light Mode
- Custom UI-Komponenten (Slider, ThemedSnackbar, Section, SettingsSection)
- Vogel-thematisierte Icons und visuelles Design-System
- Tab-Struktur mit haptischem und Audio-Feedback
- Lokale SQLite-Datenbank mit Archivfunktionalitt und Sync
- Lokalisierungssystem (6 Sprachen) mit dynamischem Umschalten
- Settings-Implementierung mit kategorisierten Bereichen
- ML-Modell-Training, -Konvertierung und -Integrations-Pipeline
- Custom Kamera-Komponente mit Echtzeit MLKit-Objekterkennung
- Zwei-Modell-Pipeline: SSD-Objekterkennung + Vogelklassifikation
- Bildklassifikation mit konfidenzbasierter Visualisierung
- BirDex-Datenbank mit 30.000+ globalen Vogelarten
- Massenbersetzungssystem mit mehreren APIs und Fallbacks
- Paginierungssystem fr Vogel-Datenbank mit Suchfunktionalitt
- Wikipedia-Integration und externe Links
- Sprite-basierte Vogelanimationen fr Hintergrund
- Erweiterte Dateiverarbeitung und Medienspeicherung
- Performance-Optimierung fr Android-Gerte (2020+)
- Audio-Pipeline fr ML-modell-konforme Datenkonvertierung
- .h5 BirdNet-Modell zu .tflite-Konvertierung und -Integration
- Unified ML Pipeline fr sequenzielle Bild- und Audio-Verarbeitung
- WhoBird Kotlin fr React Native mit TypeScript adaptiert

- Archivsystem mit vollständiger Medienunterstützung
- Robustes Species-Mapping-System mit Edge-Case-Behandlungen
- Wikipedia-Bild-Scraping-System für 30.000+ Vogelarten
- Umfassende Testsuite mit über 90% Code-Coverage

Spezialgebiete

- **Machine Learning:** TensorFlow.js Integration, MLKit, BirdNET-Modelle
- **Mobile Entwicklung:** React Native, Expo, Performance-Optimierung
- **Datenbankdesign:** SQLite, Species-Mapping, Lokalisierung
- **DevOps:** CI/CD, Build-Automatisierung, Windows-WSL2 Integration

Arbeitsaufwand

Geschätzter Arbeitsaufwand: 85% der gesamten Entwicklungszeit

- Architektur und Design: 40 Stunden
- ML-Integration und Pipeline: 60 Stunden
- UI/UX Entwicklung: 50 Stunden
- Datenbank und Lokalisierung: 45 Stunden
- Testing und Optimierung: 35 Stunden
- **Gesamt: 230 Stunden**

B.2. Luis Wehrberger - Backend & Cloud-Entwickler

Hauptverantwortlichkeiten

- Firebase-Integration und Cloud-Services
- Benutzerauthentifizierung und -verwaltung

- Cloud-Synchronisation und Datei-Upload
- Kartenintegration und Geodatenverarbeitung
- Bug-Fixes und Code-Qualitätsverbesserungen

Technische Beiträge

- Firebase und Firestore Setup
- Firebase Authentication (Registrierung, Login, Logout, Kontoverwaltung)
- Passwort-Wiederherstellungsfunktionalität
- Cloud-Synchronisationsfähigkeit mit Datei-Upload
- Erste Iteration von Foto- und Audioaufnahme-Komponenten
- Fix für infinite Log-Context-Schleifen
- Stack-Segmentierungs-Fix im Root-Layout
- Kritische Bug-Fixes für App-Stabilität
- Package.json Bereinigung und Dependency-Management
- UI-Design der Settings-Sprachauswahl bearbeitet
- Kartenkomponente für Vogelsichtungs-Geolocations
- Modal-System für Archiv-Detailansichten
- Migration zu modernen Kamera-Paketen

Spezialgebiete

- **Cloud-Services:** Firebase Authentication, Firestore, Storage
- **Geodaten:** OpenStreetMap Integration, GPS-Verarbeitung
- **Code-Qualität:** Refactoring, Dependency-Management
- **UI-Verbesserungen:** Settings-Design, Kartenvisualisierung

Arbeitsaufwand

Geschätzter Arbeitsaufwand: 12% der gesamten Entwicklungszeit

- Firebase Setup und Integration: 15 Stunden
- Authentication System: 10 Stunden
- Kartenintegration: 8 Stunden
- Bug-Fixes und Refactoring: 7 Stunden
- **Gesamt: 40 Stunden**

B.3. Youmna Samouneh - UI/UX Design & Lokalisierung

Hauptverantwortlichkeiten

- Initiale Wireframe-Erstellung
- Lokalisierungs-Unterstützung
- UI-Text-Verbesserungen
- Design-Feedback und Usability-Input

Technische Beiträge

- Erste Wireframe-Erstellung für Entwicklungsvisualisierung zu Projektbeginn
- Übersetzungsschlüssel für häufige Fehler (20 von 600 Zeilen übersetzt)
- Design-Feedback für UI-Komponenten
- Usability-Testing und Verbesserungsvorschläge

Spezialgebiete

- **UI/UX Design:** Wireframing, User Interface Design
- **Lokalisierung:** Übersetzungen, Sprachunterstützung

- **Usability:** Benutzererfahrung, Design-Feedback

Arbeitsaufwand

Geschätzter Arbeitsaufwand: 3% der gesamten Entwicklungszeit

- Wireframe-Erstellung: 4 Stunden
- Lokalisierungs-Beiträge: 2 Stunden
- Design-Feedback: 3 Stunden
- **Gesamt: 9 Stunden**

C. Teamarbeit und Kollaboration

C.1. Arbeitsaufteilung

Die Arbeitsaufteilung erfolgte basierend auf individuellen Stärken und Interessen:

Bereich	Martin	Luis	Younna
Architektur	Primär	-	-
ML/AI	Primär	-	-
Frontend	Primär	Unterstützung	Design-Input
Backend/Cloud	Unterstützung	Primär	-
UI/UX	Primär	Unterstützung	Design-Input
Testing	Primär	Unterstützung	-
Dokumentation	Primär	Unterstützung	Lokalisierung

Tab. 8.1.: Arbeitsaufteilung nach Bereichen

C.2. Kommunikation und Koordination

- **Regelmäßige Meetings:** Wöchentliche Statusupdates und Planungssitzungen
- **Git-Workflow:** Feature-Branches mit Code-Reviews
- **Dokumentation:** Umfassende README und Inline-Kommentare
- **Issue-Tracking:** GitHub Issues für Bug-Reports und Feature-Requests

C.3. Herausforderungen in der Teamarbeit

- **Ungleiche Beitragslevel:** Unterschiedliche Verfügbarkeit und Engagement der Teammitglieder
- **Technische Komplexität:** ML-Integration erforderte spezialisiertes Wissen
- **Koordination:** Synchronisation zwischen verschiedenen Entwicklungsbereichen

C.4. Erfolgreiche Kollaborationsaspekte

- **Komplementäre Fähigkeiten:** Jedes Teammitglied brachte einzigartige Expertise ein
- **Flexible Rollen:** Anpassung der Verantwortlichkeiten basierend auf Projektbedürfnissen
- **Konstruktives Feedback:** Regelmäßige Code-Reviews und Design-Diskussionen

D. Projektmanagement

D.1. Entwicklungsmethodik

- **Agile Entwicklung:** Iterative Feature-Entwicklung mit regelmäßigen Releases
- **Feature-driven:** Entwicklung basierend auf User Stories und Akzeptanzkriterien
- **Continuous Integration:** Automatisierte Builds und Tests

D.2. Meilensteine und Timeline

Meilenstein	Zeitraum	Hauptverantwortlicher
Projektsetup	Woche 1-2	Martin
Firebase Integration	Woche 3-4	Luis
ML-Pipeline Entwicklung	Woche 5-8	Martin
UI/UX Implementierung	Woche 6-10	Martin, Youmna
Testing und Optimierung	Woche 9-11	Martin, Luis
Dokumentation	Woche 12	Alle

Tab. 8.2.: Projekt-Timeline und Verantwortlichkeiten

E. Lernerfahrungen und Reflexion

E.1. Individuelle Lernerfahrungen

Martin Lauterbach

- **Technische Expertise:** Vertiefte Kenntnisse in React Native und ML-Integration
- **Projektleitung:** Erfahrung in Projektkoordination und Architekturentscheidungen
- **Problemlösung:** Systematische Herangehensweise an komplexe technische Herausforderungen

Luis Wehrberger

- **Cloud-Services:** Praktische Erfahrung mit Firebase und Cloud-Integration
- **Teamarbeit:** Kollaboration in einem größeren Entwicklungsprojekt
- **Code-Qualität:** Bedeutung von sauberem Code und Dependency-Management

Youmna Samounh

- **Design-Prozess:** Erfahrung im UI/UX-Design für mobile Anwendungen
- **Lokalisierung:** Verständnis für internationale Anwendungsentwicklung

- **Teamkommunikation:** Wichtigkeit von Design-Feedback und Benutzerperspektive

E.2. Gemeinsame Lernerfahrungen

- **Agile Entwicklung:** Wert von iterativer Entwicklung und regelmäßigem Feedback
- **Dokumentation:** Kritische Bedeutung von umfassender Projektdokumentation
- **Testing:** Notwendigkeit systematischer Tests für komplexe Anwendungen
- **Performance:** Herausforderungen der mobilen Performance-Optimierung

F. Empfehlungen für zukünftige Projekte

F.1. Teamzusammensetzung

- Ausgewogenere Arbeitsverteilung anstreben
- Klare Rollen und Verantwortlichkeiten definieren
- Regelmäßige Kommunikation und Check-ins etablieren

F.2. Projektmanagement

- Detailliertere Planung mit realistischen Zeitschätzungen
- Frühe Identifikation von Risiken und Abhängigkeiten
- Kontinuierliche Qualitätssicherung implementieren

F.3. Technische Aspekte

- Frühzeitige Prototyping für kritische Features
- Umfassende Testing-Strategie von Beginn an

- Regelmige Code-Reviews und Pair-Programming

G. Anerkennung und Dank

Das Projektteam mchte folgende Anerkennung aussprechen:

- **Prof. Dr. Arjan Kuijper:** Fr die Betreuung und fachliche Untersttzung
- **Hochschule RheinMain:** Fr die Bereitstellung der Entwicklungsumgebung
- **Open Source Community:** Fr die verfgbaren Bibliotheken und Tools
- **BirdNET Projekt:** Fr die Bereitstellung der Audio-Klassifikationsmodelle
- **MLKit Team:** Fr die zuverlssigen ML-Pakete

Das LogChirpy-Projekt demonstriert erfolgreiche Teamzusammenarbeit trotz ungleicher Beitragslevel und zeigt, wie komplementre Fhigkeiten zu einem erfolgreichen Projektabschluss fhren knnen.